



Musiksteuerung mit Brain Computer Interface

Bachelorthesis

Ina Widmer

Michael Job

Studiengang: iCompetence

Betreuer: Prof. Dr. Simon Schubiger

Auftraggeber: Angelo Nottaris

Windisch, 16. August 2018

Fact Sheet

Projektname	"Musiksteuerung mit Brain Computer Interface" 18fs_IIT15
Studiengang	iCompetence, Hochschule für Technik, FHNW
Projektdauer	20. Februar 2018 - 16. August 2018
Team	Ina Widmer, Michael Job
Auftraggeber	Angelo Nottaris
Betreuer	Prof. Dr. Simon Schubiger, Institut für Interaktive Technologien, FHNW
Source	https://github.com/Nottaris/OpenBCI_NodeJS_IP6

Zusammenfassung

Brain Computer Interfaces (BCI) auf der Basis von Elektroenzephalographie (EEG) finden den Weg aus den neurologischen Kliniken zu den Endanwendern im (Online-) Elektronikmarkt. Von Do-it-yourself und Open Source Hack-Projekten zu fixfertigen Tech-Gadgets findet man eine breite Palette von low-cost EEG-Geräten. Damit eröffnen sich zahlreiche neue Anwendungsmöglichkeiten.

In dieser Arbeit wurden die Möglichkeiten zur Steuerung eines Musikplayers mittels einem OpenBCI erarbeitet. Die Implementation des Musikplayers ist webbasiert. Verschiedene Steuerungskonzepte wurden erarbeitet – basierend auf Blinzeln, der P300-Welle und Motor Imagery. Zur Analyse der EEG-Daten wurden herkömmliche Datenverarbeitungen sowie Machine Learning-Algorithmen angewendet. Unter Ausschluss von Laborbedingungen und mit der vorhandenen Hardware konnte das Steuerungskonzept mittels Blinzeln erfolgreich umgesetzt werden. Ein Erkennen der P300-Welle sowie das Trainieren von verschiedenen mentalen Kommandos mittels Motor Imagery sind konzeptuell beschrieben und ansatzweise implementiert. Für weitere Projekte in diesem Gebiet bietet diese Arbeit eine Grundlage (Open Source) sowie Entscheidungshilfen zu low-cost EEG-Geräten und den geeigneten BCI-Steuerungskonzepten.

Abstract

Electroencephalography (EEG)-based Brain Computer Interfaces (BCI) are becoming increasingly common, finding their way from neurology clinics to end users in (online-) consumer electronic markets. Users can access a range of low-cost EEG devices, from DIY and open source hackathon projects to preassembled tech gadgets. These devices open up a world of potential new applications. In this paper, opportunities to control a web-based music player with an OpenBCI were evaluated. Different approaches – based on blinking, P300 and motor imagery, using common data processing as well as machine learning algorithms to analyse the EEG data are described. In the absence of laboratory conditions and by using available hardware, the concept of controlling the player by blinking was successfully implemented. Conceptually described and partially implemented are the concepts of P300 as well as training and detecting mental commands with motor imagery. This paper provides a useful starting point (open source) for future projects in this area of research, and it serves as a guide and decision-making tool for low-cost EEG devices and relevant concepts of BCI-controls.

Keywords

BCI, OpenBCI, EEG, P300, Motor Imagery, Machine Learning, Musicplayer

Inhaltsverzeichnis

1	Einleitung	1
2	Elektroenzephalographie.....	4
2.1	Biometrie.....	4
2.2	Gehirn	6
2.3	Verwendung der Elektroenzephalographie.....	7
2.4	Grundlagen der Elektroenzephalographie	9
3	Brain Computer Interfaces (BCI).....	16
3.1	OpenBCI	16
3.2	EEG-Hardware.....	19
3.3	EEG-Hardware Gegenüberstellung	21
4	Experimental Aufbau	22
4.1	Hardware	22
4.2	Software.....	22
4.3	Musikplayer	24
4.4	User Experience.....	26
5	Steuerungskonzepte.....	27
5.1	Steuerung durch Blinzeln	27
5.2	Steuerung durch evozierte Potentiale.....	33
5.3	Steuerung durch Gedanken	44
5.4	Steuerungskonzepte Gegenüberstellung.....	50
6	Fazit	51
7	Literaturverzeichnis	54
8	Anhang	57
8.1	Projektantrag.....	57
8.2	Aufgabenvereinbarung	58
9	Ehrlichkeitserklärung	59

Abbildungsverzeichnis

Abbildung 1 Hirnregionen (Mahler 2018, 9)	6
Abbildung 2 Hirnregionen aus Neurowissenschaften (Bear 2009)	7
Abbildung 3 Strukturen unter der EEG-Elektrode (Bear 2009)	10
Abbildung 4 VEP Muster (oftalmoskop.net 2015)	12
Abbildung 5 A normal flash VEP (Odom u. a. 2004)	12
Abbildung 6 Elektrodenplatzierung aus (Malmivuo und Plonsey 1995)	13
Abbildung 7 Bezeichnungen der Positionen aus (Wellach 2015, 57)	13
Abbildung 8 Darstellung der Zeit- und Frequenz-Domäne (squidarth 2018)	15
Abbildung 9 OpenBCI Headset	17
Abbildung 10 10-20-System, blau markiert die OpenBCI Headset Positionen	17
Abbildung 11 OpenBCI Cyton Board aus (OpenBCI 2018)	18
Abbildung 12 Muse	19
Abbildung 13 Emotiv EPOC Flex	20
Abbildung 14 Emotiv Epoc+	20
Abbildung 15 NeuroSky MindWave Mobile 2	21
Abbildung 16 Musikplayer GUI Blink mit abwechselnd weiss aufleuchtenden Kommandos	25
Abbildung 17 Schema Steuerung durch Blinzeln	28
Abbildung 18 Blinzeln in Rohdaten	29
Abbildung 19 Blinzeln in Bandpass gefilterten Daten	29
Abbildung 20 Bewusstes Blinzeln	31
Abbildung 21 Doppeltes Blinzeln	31
Abbildung 22 Rechts Zwinkern	31
Abbildung 23 Mund öffnen & schliessen	31
Abbildung 24 Typischer Prozess zur Klassifizierung von P300 (Lotte 2018, 20)	33
Abbildung 25 Musikplayer P300 (Kommando next leuchtet auf)	34
Abbildung 26 Schema Steuerung durch P300	35
Abbildung 27 EEG Signal verschiedene Bandpassfilter	36
Abbildung 28 Musikplayer Variante A	37
Abbildung 29 P300 Signal über mehrere Durchläufe	38
Abbildung 30 Musikplayer Variante B	38
Abbildung 31 Musikplayer Variante C	39
Abbildung 32 P300 Vergleich über mehrere Kanäle	40
Abbildung 33 P300 Durchschnittssignal über mehrere Durchgänge	40
Abbildung 34 P300 Aufsummieren des Signals über mehrere Durchgänge	40
Abbildung 35 Musikplayer Mind	46

Tabellenverzeichnis

Tabelle 1 Aufteilung der Gehirnströme in Frequenzbänder / Rhythmen aus (Mahler 2018)	11
Tabelle 2 Beispiel einer möglichen Belegung (Kabelfarben, 10-20-System Positionen)	18
Tabelle 3 Motor Imagery für Steuerungskonzept Mind	46

Listingverzeichnis

Listing 1 Verbindung mit OpenBCI Board herstellen und Samples streamen	23
Listing 2 Board Konfiguration	31

Abkürzungen

BCI	Brain Computer Interface
EMG	Elektro Myographie
EEG	Elektroenzephalogramm
EKG	Elektrokardiogramm
MEG	Magnetisches Enzephalogramm
ML	Machine Learning
ERP	Event Related Potential
VEP	Visually evoked potentials
P300	Bekanntes Muster eines ERP

1 Einleitung

Seit Jahrzehnten arbeiten Wissenschaftler daran die direkte Kommunikation zwischen Gehirn und Computer zu ermöglichen. Durch das Aufkommen von günstigen und komfortableren low-cost Brain Computer Interfaces (BCI) in den letzten Jahren, wurde die Technologie für einen viel grösseren Markt zugänglich und wird auch vermehrt für kommerzielle Produkte eingesetzt. Grundsätzlich kann ein Brain Computer Interface zur Steuerung aller möglichen Geräte und / oder Programme genutzt werden. In dieser Arbeit wurde konkret die Steuerung einer Musikabspiel-Software (im Weiteren "Musikplayer") verfolgt. Die der Arbeit zu Grunde liegende Idee eines Kopfhörers mit integrierten Elektroden, stammt aus der Bachelor-Thesis Industrial Design von Angelo Nottaris (Nottaris 2017). Die Grundlage von BCI bildet die Elektroenzephalografie (EEG), eine Technik aus der Medizin, mit der mittels Elektroden die Hirnstromaktivität gemessen werden kann. Diese Daten zu analysieren und damit eine Steuerung zu ermöglichen, ist die Grundidee eines Brain Computer Interfaces. So können beispielsweise Locked-in¹ Patienten mittels Elektrodenkappe Buchstaben auf einem Bildschirm auswählen oder einen Roboterarm steuern.

In diesem Projekt sollen unterschiedliche Interaktionsmöglichkeiten mit Hilfe von BCI untersucht werden. Ein Musikplayer soll als Ziel der Steuerung aufgebaut werden. Als Zielgruppe der Anwendung gelten Tetraplegiker, da sie besonders von alternativen Steuerungstechniken profitieren können. Die Grundfunktionalitäten des Musikplayers, wie das Regeln der Lautstärke, das Wechseln zwischen Songs sowie Starten und Pausieren eines Songs, sollen mit dem BCI gesteuert werden können. Es soll in dieser Arbeit untersucht werden, ob sich ein Brain Computer Interface für diese Aufgabe eignet. Die Interpretation der gemessenen Daten durch den Computer stellt eine Herausforderung dar. Da die Anwendung nicht im Labor, sondern für Endanwendende nutzbar sein soll, muss geprüft werden, ob Störsignale und andere Einflüsse ausgeschaltet werden können.

Das Projekt wird ausschliesslich mit Open Source² Hard- und Software entwickelt, damit es künftig als Grundlage dienen kann für weitere BCI Projekte. Als Hardware wurde in diesem Projekt ein OpenBCI³ EEG Headset verwendet. Diese Hardware wurde vom Auftraggeber zur Verfügung gestellt. Konkurrenzprodukte im ähnlichen Preissegment wurden untereinander verglichen. Eine Empfehlung, welche Hardware sich am ehesten für welches Steuerungskonzept eignet wurde erarbeitet.

¹ Von "locked-in" spricht man bei kompletten Lähmungserscheinungen inklusive des Verlustes der Sprache. (Kübler u. a. 2009)

² "Als Open Source (aus englisch open source, wörtlich offene Quelle) wird Software bezeichnet, deren Quelltext öffentlich und von Dritten eingesehen, geändert und genutzt werden kann. Open-Source-Software kann meistens kostenlos genutzt werden." („Open Source“ 2018)

³ Open Source Community BCI (OpenBCI 2018)

Nach dem Einarbeiten in die EEG-Grundlagen und dem Studieren anderer BCI Projekte wurden drei Steuerungskonzepte mittels dem OpenBCI ausgearbeitet. Es wurden drei Steuerungskonzepte ausgewählt, die unterschiedlichen Hirnaktivitäten zur Steuerung benutzen und bereits gut erforscht sind. Zum Schluss wurde analysiert, welche Steuerungskonzepte sich für welche Interaktionen eignen.

Als erstes Steuerungskonzept wurde das EEG-Signal eines Augenschliessens verwendet. Mehrere Projekte verwenden das bewusste Blinzeln für die Steuerung. Ein Beispiel ist das Projekt WinkIt (Matran-Fernandez 2015), welches an einem Hackathon („hack-the-brain-uk“ 2015) unter Mitwirkung von OpenBCI-Mitarbeitern entstanden ist. Es wurde durch zwei PhD-Studierende mit Hilfe von Fördergeldern vorangetrieben. WinkIt ist eine Smartphone App, bei welcher man verschiedene Kommandos dem rechten oder linken Augenzwinkern zuordnen kann. Durch das Zwinkern werden diese dann ausgelöst.

Anhand der EEG Daten lassen sich verschiedene Bewusstseinszustände, wie Aufmerksamkeit, Konzentration, Wach- und Schlafzustand ableiten. Auditive, visuelle und weitere Eindrücke beeinflussen die Hirnströme.

Das zweite Konzept verwendet ein visuell evoziertes Potential zur Steuerung. Auf einem visuellen Ereignis basierende Merkmale, sogenannte Visually evoked potentials (VEP) werden seit langem in verschiedenen Projekten verwendet, um Locked-in Patienten eine Möglichkeit zur Kommunikation zu geben. Hier sind vor allem die P300-Speller zu nennen. Ein Bildschirm zeigt eine Matrix bestehend aus den Buchstaben des ABC. Die einzelnen Reihen und Spalten blinken in schneller Folge auf. Durch die Konzentration des Anwendenden auf ein bestimmtes Zeichen, kann dieses selektiert werden, zum Buchstabieren respektive Schreiben von Wörtern. Ein P300-Speller ist somit eine Chance um wieder eine Kommunikation zu ermöglichen. Basierend auf dem P300 Speller Konzept wurde ein zweites Steuerungskonzept für den Musikplayer erarbeitet.

Als letztes Konzept wurde eine Gedankensteuerung erarbeitet. Kann ein EEG direkt Gedanken lesen? Das muss verneint werden. Ob eine beliebige Person an die Farbe Blau oder an die Farbe Rot denkt, wird auch mit ausgereifter Technologie nicht so schnell festzustellen sein. Was jedoch möglich ist, sind die unterschiedlichen Spannungspotentiale zu beurteilen. Diese unterscheiden sich, ob man an eine Bewegung denkt oder ob man visuelle Eindrücke zu verarbeiten hat. Die Gehirnströme lassen sich also durch auditive, visuelle und weitere Eindrücke beeinflussen. Und die dem vermessenen Subjekt eigne Konzentration und Vorstellungskraft kann ebenfalls verschiedene Muster hervorrufen. Werden diese individuellen Muster richtig trainiert, sowohl als Subjekt, wie für die Analysealgorithmen, so lassen sich diese auch wiedererkennen und zur Auswertung verwenden. So ist durchaus denkbar, dass durch vorangehendes Training der beiden visuellen Eindrücke Blau und Rot ein EEG-System für diese

spezifische Person und diese spezifische Aufgabe bestimmen kann, auf welche Farbe momentan gerade fokussiert wird. Dies entspricht aber keinesfalls einem Gedankenlesen.

Diese Technik wird beispielsweise verwendet zum Steuern von Drohnen oder Games. Dabei wird mit einem EEG-Headset, die Aktivität des Hirns mit gewissen Gedanken verknüpft. Als wiedererkennbare Gedanken eignen sich besonders motorischen Bewegungen, die sich der Anwender vorstellt. Zum Beispiel das Bewegen der linken oder rechten Hand oder Fussbewegungen. Diese Bewegungen als mentale Tasks werden mit den EEG-Signalen verknüpft, welche dann als Signal für die Steuerung dienen. So kann beispielsweise eine Drohne mit vier mentalen Tasks gelenkt werden, indem der Anwender sich die entsprechenden Bewegungen vorstellt. (Siehe "Quadcopter control using a BCI" (Rosca u. a. 2018)). In der Arbeit "Development of a Novel Motor Imagery Control Technique and Application in a Gaming Environment" (Li u. a. 2017) kann der Anwendende ein 3D-Tetris durch mentale Tasks steuern.

Die möglichen Anwendungsgebiete einer Auswertung von EEG Daten sind neben der klinischen Bedeutung also sehr vielfältig. Sei dies, um neue Interaktionsmöglichkeiten ganz allgemein zu fördern, oder um Personen mit Behinderungen eine Interaktion überhaupt zu ermöglichen.

Die Arbeit hat folgenden Aufbau: Im Kapitel 2 Elektroenzephalographie wird die Biometrie als Oberbegriff der Elektroenzephalographie erläutert, um danach spezifisch auf die EEG-Methode einzugehen. Was ein Brain Computer Interface ist und welche Hardware dafür erhältlich ist, wird im Kapitel 3 Brain Computer Interfaces (BCI) beschrieben. In Kapitel 4 Experimental Aufbau werden die in dieser Arbeit verwendeten Hardware- und Software-Komponenten vorgestellt. Die erarbeiteten Steuerungskonzepte mit den durchgeführten Experimenten sind im Kapitel 5 Steuerungskonzepte aufgeführt. Kapitel 6 Fazit fasst die Erkenntnisse dieser Arbeit zusammen.

2 Elektroenzephalographie

Die Elektroenzephalographie (EEG) ist ein Bereich der Biometrie. Unter Biometrie versteht man das Messen von biologischen Parametern. In diesem Kapitel werden die verschiedenen Bereiche der Biometrie kurz vorgestellt. Zur Steuerung des Musikplayers via OpenBCI werden die Möglichkeiten der Elektroenzephalographie verwendet. Die zugrunde liegenden Strukturen des Gehirns, welche die Signale aussenden, werden in Kapitel 2.2 erläutert. In Kapitel 2.3 wird die Verwendung des EEG beschrieben. Die Grundlagen der Elektroenzephalographie werden in Kapitel 2.4 beschrieben.

2.1 Biometrie

Durch die Entwicklung der Computertechnik und die stark gefallen Preise für elektronische Bauteile boomen Messsysteme, welche unsere Körper überwachen. Schrittzähler gab es bereits vor der starken Smartphone-Durchdringung, seitdem nimmt auch die Zahl an sogenannten Fitness Trackern zu. Ein Armband oder eine Uhr, die den Puls misst, die Schritte zählt und weitere Daten zur Analyse und Visualisierung an das Smartphone sendet. Diese Art von Biosensoren hat also bereits den Mainstream erreicht. In der Medizin und der Forschung bestehen weitere Arten von Biosensoren. Diese werden in der Medizin zur Diagnose und teilweise auch zur Therapie eingesetzt. Einzelne Firmen wie beispielsweise iMotions („iMotions: Biometric Research, Simplified“ 2018) spezialisieren sich auf die Biometrie. Im Folgenden werden einige Arten der Biometrie mit Ihren hauptsächlichen Anwendungsgebieten beschrieben. Dies insbesondere deshalb, weil die verschiedenen Metriken oftmals auch kombiniert analysiert werden. Den Grundlagen der Elektroenzephalographie (EEG) ist das Kapitel 2.4 gewidmet, da dies die Grundlage des Brain Computer Interfaces darstellt. (Mahler 2018)

Eyetracking

Das Aufzeichnen von Augenbewegungen geschieht mittels eines Kamerasystems, das die Pupillen lokalisiert. Daraus lässt sich die Blickrichtung, also was angeschaut wird, ablesen. Gleichzeitig wird die Pupillengröße gemessen. Dies gibt Aufschluss über die Erregung und den Stresslevel der Person. Eine Pupillenerweiterung oder Verengung passiert unbewusst und kann nicht willentlich gesteuert werden. Eyetracking wird häufig von der Psychologie in Usability Labors angewendet um beispielsweise Webseiten zu testen. Wohin schaut der User, wann, wie lange, usw. (Mahler 2018)

Hautreaktion

Galvanic Skin Response (GSR) oder Electrodermal Activity (EDA) nennt man die Verfahren, bei denen durch Sensoren auf der Haut die Schweissabsonderung gemessen werden kann. Diese ist durch emotionale Schwankungen beeinflusst und wird von tieferen, älteren Hirnregionen gesteuert als unsere

bewussten Handlungen wie beispielsweise motorische Bewegungen. Somit erhält man zusätzliche Hinweise auf die emotionale Verfassung eines Probanden. (Mahler 2018)

Gesichtsausdrücke

Durch die Verwendung einer einfachen Kamera, wie einer Webcam, kann in einer Laborsituation das Gesicht der Probanden und Probandinnen aufgezeichnet werden. Mittels Software können dann die Gesichtsausdrücke erkannt und aufgezeichnet werden. Im Verbund mit anderen Biosensoren wie ein EEG, kann man dadurch noch genauere Analysen erstellen. Die Gesichtsmuskulatur lässt sich zwar willentlich bewegen, es gibt aber dennoch viele kleine Merkmale, die erkannt werden können. Diese sind zum Teil auch unbewusst in unseren Gesichtern präsent, ein absolut ideales Pokerface ist also nicht einmal sehr guten Schauspielern gegönnt. (Mahler 2018)

Elektromyographie (EMG)

Die Sensoren eines EMG zeichnen die elektronischen Signale von Körperbewegungen auf. So lassen sich Reaktionen von Gesichts-, Hand- und Fingermuskulatur usw. auf verschiedene Stimuli untersuchen. Analog zum Gesichtsausdruck, dies aber eben nicht visuell, sondern durch die Muskelaktivität. Wird eine Person beispielsweise erschreckt, so lässt sich bereits eine Spannung in der Muskulatur feststellen, auch wenn gar keine sichtbare Bewegung erfolgt. (Mahler 2018)

Elektrokardiographie (EKG)

Die Aufzeichnung des Herzrhythmus ist wohl eines der bekanntesten Biometrie Verfahren aus der Medizin. Durch Elektroden am Brustkorb oder einen optischen Pulsmesser Clip an der Fingerspitze (Pulsoxymetrie) lässt sich die Herzschlagrate bestimmen. Diese beeinflusst die Signale eines EEG wesentlich und ist somit hilfreich bei der Reduzierung von Artefakten. (Mahler 2018)

Magnetoenzephalographie (MEG)

Die Gehirnaktivitäten lassen sich im Labor durch aufwändige und teure Gerätschaften messen. Ein Magnetoenzephalograph (MEG) kann in einem magnetisch abgeschirmten Raum die sehr feinen Magnetfelder messen, welche durch die Potentiale im Gehirn entstehen. Der Vorteil der MEG gegenüber EEG liegt in der besseren Messung von hohen Frequenzen über 60Hz. Dies beruht darauf, dass magnetische Felder die Schädeldecke, Haut und Haare durchdringen können während die elektronischen Signale für das EEG durch diese Strukturen gedämpft werden. (Singh 2014)

2.2 Gehirn

Das Gehirn ist das Hauptorgan des menschlichen Zentralnervensystems. Es besteht aus rund 100 Milliarden Nervenzellen, welche miteinander über Synapsen verbunden sind. Der Aufbau lässt sich grob in acht Regionen aufteilen, welche unterschiedliche Funktionen innehaben. (Mahler 2018, 13)




Abbildung 1 Hirnregionen (Mahler 2018, 9)

- 1 Der **Hirnstamm** ist der älteste Teil des Gehirns. Er kontrolliert autonome Körperfunktionen wie den Herzschlag, die Atmung und den Gleichgewichtssinn.
- 2 Das **limbische System** ist für die Verarbeitung von Emotionen zuständig. Das limbische System reagiert sofort auf Gedanken, Gefühle und Wahrnehmungen und sendet diese Informationen an den Hirnstamm. Dadurch werden gefühlsmässige Reaktionen auf Umweltreize ausgelöst.
- 3 Das **Kleinhirn** oder Cerebellum ist zuständig für die Steuerung der Motorik. Es dient als Kontrollinstanz für die Koordination und Feinabstimmung von Bewegungsabläufe.
- 4 Das **Grosshirn** oder Cerebrum bildet den grössten Teil des menschlichen Gehirns. Es ist verantwortlich für viele Denk- und Handlungsprozesse. Das Grosshirn besteht aus zwei Teilen, die nicht direkt verbunden sind.
- 5 Der **Okzipitallappen** gehört zum Sehzentrum des Gehirns. Er ist verantwortlich für die Verarbeitung visueller Reize der Augen.
- 6 Der **Temporallappen** enthält den primären auditorischen Cortex (das Hörzentrum) und das Sprachzentrum. Er ist auch zuständig für das Langzeitgedächtnis.
- 7 Der **Parietallappen** spielt eine wichtige Rolle bei der Integration von sensorischen Informationen. Es ist zuständig für die visuelle Steuerung von Bewegungen, das Erkennen von Reizen und das räumliche Denken.
- 8 Der **Frontallappen** ist für die motorischen Funktionen und Bewegungen, die aktiv vom Bewusstsein ausgelöst werden zuständig. Der Frontallappen reguliert auch kognitive Prozesse, dadurch können situationsgerechte Handlungen ausgeführt werden. (Mahler 2018, 10)

Die Gehirnareale können neben anatomischen Strukturen auch nach funktionellen Strukturen eingeteilt werden. In der folgenden Abbildung 2 sind farblich abgegrenzt die Bereiche für die Motorik, die Sensorik und assoziative Zonen ersichtlich. Alle diese Einteilungen sind eine grobe Vereinfachung der komplexen Wirklichkeit. Dank neuer Technologien können diese immer besser erforscht werden, sie sind aber bei weitem noch nicht vollständig ergründet.




Abbildung 2 Hirnregionen aus Neurowissenschaften (Bear 2009)

2.3 Verwendung der Elektroenzephalographie

Die ersten Versuche bei Tieren mittels Elektroden Signale vom Hirn abzuleiten, welche durch Sinneswahrnehmungen beeinflusst sind, fanden bereits 1875 in Grossbritannien durch Richard Canton statt. Das allererste Elektroenzephalogramm am Menschen wurde 1924 durch den deutschen Neurologen Hans Berger (*1873 †1941) erstellt. Dabei wurden die Elektroden allerdings durch die Schädeldecke hindurch (Trepanation) direkt an der Grosshirnrinde angebracht. Glücklicherweise haben sich die technischen Hilfsmittel bis heute bedeutend weiterentwickelt, so dass nichtinvasive Verfahren möglich sind. (Bauer und Berger 2011)

Die Elektroenzephalographie (EEG) eignet sich gut um neurokognitive Prozesse im Gehirn zu untersuchen. Die neuronalen Vorgänge aufgrund von Stimuli wie Sehen, Hören, Bewegen usw. passieren sehr schnell. Ein EEG ist fähig diese schnellen Veränderungen aufzuzeichnen. Es eignet sich jedoch nicht gut, um einen Vorgang im Gehirn genau zu lokalisieren. Die topologische Zuordnung kann anhand der Signale der verschiedenen Elektroden abgeleitet werden. Ob die Signale aber auch aus den direkt darunterliegenden Gehirnstrukturen kommen oder von anderen Stellen aus dem Gehirn ist dadurch nicht festzustellen. In welcher Hirnregion genau ein Prozess vorgeht oder eine Information

gespeichert wird zeigt sich nicht durch ein EEG. Dies entspräche einer Gehirn Lokalisation, dazu benötigt man die weitaus aufwändigere Technik der funktionellen Magnetresonanztomographie (fMRT). (Cohen 2014, 27)

Die Erstellung von Elektroenzephalogrammen kann über verschiedene Funktionsstörungen des Gehirns Aufschluss geben und wird vorwiegend bei diagnostischen Routineverfahren in der klinischen Neurologie verwendet. Das EEG wird verwendet für die Analyse epileptischer Muster, Schlafdiagnostik oder bei Untersuchungen von lokalen Veränderungen im Gehirn (Hirntumore oder Durchblutungsstörungen). In der Hirntoddiagnostik kann ein EEG als Nachweis der Diagnose eines endgültigen klinischen Hirntodes dienen. (Wellach 2015, 361) In grösseren psychiatrischen Kliniken werden EEG zur Diagnostik eingesetzt.

Erlebnisbericht: Besuch der Psychiatrischen Universitätsklinik Zürich

Um einen ersten Einblick in die Arbeit und Analysemöglichkeiten eines EEG zu erhalten besuchten wir zusammen mit dem Auftraggeber Herrn Nottaris, Herrn Lirgg, EEG-Spezialist der Psychiatrischen Universitätsklinik Zürich („Home - Psychiatrische Universitätsklinik Zürich (PUK)“ 2018). Er untersucht PatientInnen mit unterschiedlichen Krankheitsbildern. Darunter sind vor allem psychische Störungen, beispielsweise eine Epilepsie sowie Vorfälle von Medikamentenmissbrauch, Drogenabhängigkeiten und Schlafstörungen. Letztere sind oft die Folge von psychischen Erkrankungen. Das EEG stellt eine Ergänzung zu weiteren Untersuchungen (Blutbild u.a.) dar. Es lassen sich sehr viele Informationen daraus ableiten. Die Erfahrung des Anwenders stellt einen wesentlichen Teil der Qualität der Expertise dar. Herr Lirgg führt die Untersuchungen mit den Patienten und den Patientinnen durch und gibt die Ergebnisse und Auswertungen an den behandelnden Arzt weiter.

Einflüsse von elektronischen Geräten wie Leuchten und Mobiltelefone etc. gilt es zu minimieren. Eine Anforderung die im Labor am ehesten realisierbar ist. Das EEG Labor besitzt dazu einen separaten kleinen Raum innerhalb des Labors, welcher als faradayscher Käfig aufgebaut ist, um möglichst reine Daten zu erhalten. Die Patienten und die Patientinnen tragen das EEG, eine netzartige Kappe, und sitzen auf einem bequemen Liegestuhl. Mittels Sichtfenster und Video/Audio Verbindung ist die Kommunikation zwischen UntersucherIn und PatientIn gewährleistet. Eine erste Analyse ist jeweils der Wachzustand. Es gibt viele Übergangsstufen von wach sein zu den Schlafphasen. Es gibt Patienten und Patientinnen, die berichten, sie seien „gut wach“, vielleicht etwas müde, um dann auf dem Stuhl umgehend einzuschlafen, teilweise auch in tiefe Schlafphasen. In leichten Schlafphasen bleiben Sie dann zwar ansprechbar, aber sind was die Hirnströme anbelangt nicht wirklich wach. Rund 80 % der Menschen zeigen

einen Grundrhythmus von 8-13 Hz (Alpha). Die restlichen 20 % können als Grundrhythmus auch Theta oder Beta zeigen. Was dies im Detail bedeutet wird in Kapitel 0 beschrieben.

Der Besuch war ein idealer Einstieg in die Materie und gab wertvolle Hinweise auf die verschiedenen Aspekte der Enzephalographie. Wir bedanken uns bei Herrn Lirgg für den freundlichen Empfang.

EEG-Biofeedback oder Neurofeedback ist eine Methodik die mittels der abgeleiteten EEG Signale dem Patienten eine Rückmeldung (Feedback) gibt über seine Hirnfunktionen. Diese beinhalten Konzentration, Gedächtnis, hohe Leistung aber auch Entspannung sowie Kreativität. Als Training angewendet, können die verschiedenen Aktivitäten gezielt geübt werden. Stress, Belastungen, Schmerzen sowie Aufmerksamkeitsdefizite beeinflussen unsere Hirnaktivitäten. Durch ein Neurofeedback-Training lassen sich solche Einflüsse beobachten, respektive die Gehirnwellenmuster reorganisieren. (Neurofeedback Organisation Schweiz 2018)

Auf die verschiedenen pathologischen EEG-Merkmale wird in dieser Arbeit nicht eingegangen, da sie für die hier bearbeitete Fragestellung nicht relevant sind. Die interessierten Leser und Leserinnen finden eine ausführliche Literatur dazu unter anderem im Praxishandbuch EEG (Wellach 2015).

2.4 Grundlagen der Elektroenzephalographie

2.4.1 Nervenzellen und elektrische Potentiale

Im Nervensystem gibt es Strukturen, die Ladungen erzeugen bzw. aufnehmen und transportieren können. Dadurch können elektrische Ströme fließen und es entstehen elektrische Felder. (Wellach 2015, 23) Die Grundlage dazu sind die Neuronen (Nervenzellen). Sie besitzen die Fähigkeit, elektrische Ladungen zu transportieren. Die Nervenzellen sind erregbar, erregungserzeugend und erregungsleitend. (Wellach 2015, 27) Die Wellen des EEG entstehen durch fortgeleitete Signalprozesse an Zellkörpern und Zellausläufern von Nervenzellen hauptsächlich in oberflächlichen Schichten der Hirnrinde. Als “Quellen” des EEG werden dabei insbesondere die Pyramidenzellen⁴ bezeichnet, welche durch ihre Ladungsänderungen diese Potentiale erzeugen. (Wellach 2015, 35)

In Abbildung 3 ist die Schädeldecke mit den darunterliegenden Strukturen schematisch dargestellt. Eine Elektrode ist auf der Kopfhaut platziert. Diese leitet die Signale an den EEG-Verstärker ab. Die Strukturen, insbesondere die Schädeldecke und die Haare, reduzieren das Signal in der Qualität und Stärke.

⁴ Pyramidenzelle ist ein Sammelbegriff für alle großen Nervenzellen, welche einen pyramidenförmigen Zellkörper haben. (Wellach 2015, 35)




Abbildung 3 Strukturen unter der EEG-Elektrode (Bear 2009)

Im Kontext von nichtinvasiven EEG sind die neuronalen Netzwerke im Gehirn in drei unterschiedliche räumliche Grössen zu unterteilen. Die mikroskopischen Einheiten umfassen weniger als ein paar Kubikmillimeter und repräsentieren Verbände von Neuronen und Synapsen. Vorgänge in diesen Bereichen sind praktisch nicht sichtbar für ein EEG, weil sie entweder gar keine oder zu schwache Signale produzieren um durch die Kopfhaut hindurch aufgenommen werden zu können. Die nächstgrössere Unterteilung wird als mesoskopische⁵ Einheit bezeichnet. Dieser Bereich umfasst mehrere Kubikmillimeter bis zu wenigen Kubikzentimetern. Dynamische Prozesse in dieser Grössenordnung können durch ein EEG aufgezeichnet werden, benötigen jedoch eine Hardware mit 64 oder mehr Elektroden. Die dritte Einheit, die makroskopische, umfasst relativ grosse Bereiche des Gehirns ab mehreren Kubikzentimetern. Potentiale aus diesen Bereichen können einfach aufgezeichnet werden, selbst mit wenigen Elektroden. (Cohen 2014, 26)

⁵ mesoskopisch: liegt zwischen mikroskopisch und makroskopisch als Masseinteilungen einer Grössenordnung

2.4.2 EEG Rhythmen / Frequenzbänder

"EEG-Rhythmen sind repetitive, intervallfrei aneinandergelagerte EEG-Potentiale einer charakteristischen Frequenz (Frequenzspektrum) in einer längeren zeitlichen Abfolge (z.B. Alpharhythmus: 8 – 12 Hz)". (Wellach 2015) Anhand ihrer Frequenz werden die EEG-Rhythmen in verschiedene Frequenzbänder aufgeteilt. Es wird vermutet, dass Zellverbände (auch Generatoren genannt) aus tief liegenden Arealen sich in bestimmten Frequenzen entladen. Diese Impulse werden weitergeleitet und zeigen die hier erwähnten Grundrhythmen (Wellach 2015)

Frequenzband		Zustände und Aktivitäten
Delta δ	1 – 4 Hz	Tiefschlaf, Schlaf und Schlafstörungen
Theta θ	4 - 8 Hz	Tiefe Entspannung, Meditation, Wachträume Schwierige mentale Aufgaben, Lernen, Erinnern
Alpha α Grundrhythmus	8 - 12 Hz	Leichte Entspannung, nach innen gerichtete Aufmerksamkeit, geschlossene Augen Meditation, Biofeedbacktraining
Beta β	12 - 25 Hz	nach aussen gerichtete Aufmerksamkeit, Hellwach, hohes Beta Angstzustände Bewegungskontrolle, Aufmerksamkeit
Gamma γ	> 25 Hz	Anspruchsvolle Tätigkeiten mit hohem Informationsfluss Mikrosakkaden ⁶

Tabelle 1 Aufteilung der Gehirnströme in Frequenzbänder / Rhythmen aus (Mahler 2018)

2.4.3 Event related potentials (ERP)

Die Potentiale im Gehirn werden nicht nur durch den Schlaf- oder Wachzustand, die Konzentration und unsere Gedanken geprägt. Auch visuelle, auditive und weitere Einflüsse, welche wie alle Sinneswahrnehmungen im Gehirn verarbeitet werden, beeinflussen die Hirnströme. Werden durch konkrete Vorkommnisse (Events) spezifische EEG-Muster hervorgerufen, so spricht man von evozierten Potentialen respektive von ERPs. Eine Untergruppe davon sind die visuell evozierten Potentiale (VEP). Es gibt verschiedene Möglichkeiten ein VEP zu generieren. Je nach verwendetem Stimulus ergeben sich unterschiedliche Hirnstrommuster. Unter verschiedenen Merkmalen, hat sich die P300 Welle als bekanntestes Muster durchgesetzt.

Im Wesentlichen misst man die EEG-Signale während des Ereignisses (Stimulus) mehrmals. Während sich durch verschiedene Faktoren wie Atmung, Bewegung, Blinzeln usw. die Nebengeräusche (Noise) verändern, sollte das Signal durch den Stimulus immer gleich oder zumindest ähnlich sein. Durch ein Mitteln aller Trials (wiederholten Messwerten) reduzieren sich die Noise Werte. Das Signal bleibt bestehen und wird dadurch "sichtbar". (Cohen 2014, 97)

⁶ Mikrosakkaden: kleinste Einstellbewegungen der Augen zur genauen Fixation (Goersch 2001, 186)

P300

Die P300 Welle bezeichnet einen positiven Ausschlag, welcher ungefähr 300 ms nach dem auslösenden Reiz auftritt. Daher kommt der Name P300. Die Zeit (Latenz) bis zum Auftreten kann je nach Subjekt variieren. Die Kurve wird daher auch zur Messung der Aufmerksamkeit verwendet. (Rupp 2018)

Die P300 Welle wird dadurch hervorgerufen, dass einem Testsubjekt ein Reiz wiederholt gezeigt wird, um danach einen neuen Reiz hinzuzufügen, welcher die P300 Welle hervorruft.

Wie bereits erwähnt, lassen sich verschiedene visuelle Stimuli verwenden. Ein Aufblitzen wird als "flash VEP" bezeichnet. Es gibt daneben noch sogenannte "reversal VEP" und "onset- offset-VEP". Erstere kommen durch ein Schachbrett zustande, bei welchem sich die Felder schwarz/weiss invertieren, also blinkend abwechseln. Letztere durch ein kontrastreiches Muster wie ein Schachbrett, welches sich mit einer gleichmässig hellen einheitlichen Fläche abwechselt (siehe Abbildung 4 VEP Muster).




Abbildung 4 VEP Muster (oftalmoskop.net 2015)

Ein bekanntes Beispiel, bei dem ein gezieltes Hervorrufen einer P300 Welle verwendet wird, sind die "P300 speller", welche in der Einleitung bereits erwähnt wurden. Diese Anwendungen erlauben es Wörter zu buchstabieren. Dem oder der Anwendenden wird das gesamte Alphabet als Matrix dargestellt. In schneller Abfolge leuchten jeweils die einzelnen Zeilen und Spalten auf. Die Anwendenden konzentrieren sich auf den Buchstaben, den sie schreiben möchten. Bei jedem Aufleuchten der Zeilen oder Spalten, welche den Buchstaben enthalten, wird die Aufmerksamkeit des Anwendenden angeregt und es wird eine P300 Welle ausgelöst. Die P300 Speller verwenden das "flash VEP" (siehe Abbildung 5 A normal flash VEP (Odom u. a. 2004)).




Figure 4. A normal flash VEP.

Abbildung 5 A normal flash VEP (Odom u. a. 2004)

Effekt durch Flimmern

Durch ein Flimmern (flicker effect), beispielsweise durch das Licht eines Stroboskops, beginnt der visuelle Cortex in derselben Frequenz zu schwingen. Mittels EEG könnte man somit feststellen, welche von zwei unterschiedlich schnell flimmernden Darbietungen angeschaut werden. Bis sich die Frequenz jedoch eingependelt hat dauert es bis zu einer Sekunde. Entsprechend muss eine längere Zeit (einige Sekunden) evaluiert werden, um ein klares Signal zu erhalten. (Cohen 2014, 101) Ein Projekt, das sich

diesen Effekt des „Visual entrainment“ zu nutzen gemacht hat, ist ein spielerischer Hack, um einen kleinen Spinnenroboter zu kontrollieren. (Chip 2014)

2.4.4 Elektroden

Damit die Elektroden bei unterschiedlichen Kopfgrößen und Formen möglichst gleich platziert werden, wurde durch Herbert Jasper ein Platzierungssystem definiert. Dieses gilt als internationaler Standard zur Platzierung von Elektroden. Dabei wird die Strecke über den Schädel vom Nasion (am oberen Ende des Nasenbeins) bis zum Inion (dorsaler Knochenvorsprung am Hinterkopf) in Prozentbereiche aufgeteilt. Eine Skizze veranschaulicht die Anordnung der Elektroden.




Abbildung 6 Elektrodenplatzierung aus (Malmivuo und Plonsey 1995)




Abbildung 7 Bezeichnungen der Positionen aus (Wellach 2015, 57)

Die verschiedenen Positionen werden mit Buchstaben-Zahlen-Kombinationen bezeichnet. Dabei repräsentieren gerade Zahlen die rechte Hemisphäre des Gehirns, ungerade die Linke. “F” steht für Frontal, “O” für Okzipital, “T” für Temporal usw. Abbildung 6 zeigt die wichtigsten Bezeichnungen.

Referenzelektrode

Beim Aufzeichnen von EEG Daten wird immer eine Elektrode als Referenz angeschlossen. Die gemessenen Spannungen sind die Differenzen zwischen der Referenz und der am gewünschten Messpunkt platzierten Elektrode. Die Platzierung der Referenzelektrode ist beim EEG häufig am Ohr, bei gewissen EEG-Headsets auch am Mastoid Knochen (hinter dem Ohr). Idealerweise würde die Referenzelektrode keine “gesuchten” Signale aufnehmen, dies ist aber in der Praxis nie exakt der Fall. Somit ist festzuhalten, dass es auch keine ideale Referenz (-position) gibt. (Wellach 2015, 79)

2.4.5 Polaritätskonvention

Die allgemeine Darstellung in Diagrammen, von positiven Werten oberhalb der Nulllinie und negativen Werten unterhalb dieser, wurde in der Elektrophysiologie gerade umgekehrt. Auch wenn sich nicht alle EEG Darstellungen daranhalten, so ist durch die Polaritätskonvention festgelegt (wenn auch willkürlich), dass Potenziale nach oben als negativ und Potenziale mit einem Ausschlag nach unten als positiv definiert werden. (Wellach 2015, 17)

Vereinzelte Darstellungen in dieser Arbeit halten sich ebenfalls nicht an diese Konvention, insbesondere dort wo Abbildungen aus der Literatur übernommen worden.

2.4.6 Störsignale und Artefakte

Verschiedenste Einflüsse behindern eine exakte Aufnahme der Potentiale. Als Störsignal sind alle externen Einflüsse, wie beispielsweise die Netzspannung zu verstehen. Als Artefakt gelten Ausschläge in den EEG Daten, welche durch ein Ereignis entstehen, welches man nicht messen will. Beispielsweise ist der Ausschlag eines Blinzeln beim Untersuchen der EEG Wellen als Artefakt zu bezeichnen. Sollen jedoch gerade das Schliessen der Augen entdeckt werden, so ist dies das Signal und beispielsweise eine Kopfbewegung oder ein Augenreiben würde ein Artefakt verursachen.

Wie erwähnt sind bereits die Schädeldeckendicke und die Haare eine Barriere. Die Leitfähigkeit der Kopfhaut wird durch Schwitzen (Störfrequenz <1 Hz) und ganz allgemein durch ihre Beschaffenheit ebenfalls beeinflusst. So sind beispielsweise auch die Augen ein Einflussfaktor. Der vordere Augenpol (Cornea) ist positiv geladen und der hintere Augenpol (Retina) ist negativ geladen. Augenbewegungen verschieben somit diese beiden Pole und beeinflussen somit die umliegenden Spannungsfelder. Allgemeine Bewegungsartefakte sind um 1-3 Hz, Muskel Artefakte zeigen rasche Frequenzen um 50 Hz.

Die im selben Raum befindlichen elektronischen Geräte beeinflussen die Messungen ebenfalls. Deshalb wird im klinischen Bereich die Messung in einem faradayschen Käfig gemacht, um umliegende Störquellen auszuschliessen. Die Netzspannung verursacht ein Brummen bei 50 Hz bei uns in der Schweiz, in den USA z.B. bei 60 Hz. (Wellach 2015, 62–105)

Frequenzfilter

Um Störsignale heraus zu filtern oder nur gewisse Frequenzbänder durch zu lassen (pass), werden Filter eingesetzt. Als Hochfrequenzfilter bezeichnet man einen Filter, der hohe Frequenzen rausfiltert und somit nur tiefere Frequenzen des Signals durchkommen lässt. Daher auch das Synonym Tiefpassfilter. Im Unterschied dazu entfernt der Tieffrequenzfilter die tiefen Frequenzen und lässt die höheren passieren (Hochpassfilter). (Cohen 2014, 179) Durch die Kombination eines Tief- und eines Hochpassfilters erreicht man den Effekt eines sogenannten Bandpassfilters. Dieser hat die Aufgabe, das Frequenzband durch zu lassen und unter- und oberhalb des Bereiches zu filtern. An der Kopfoberfläche erreichen die Hirnströme einen Frequenzbereich von 0 - 30 Hz. Somit empfiehlt sich die Verwendung von Filtern ausserhalb dieser Grenzen, um keine relevanten Signale raus zu filtern. (Wellach 2015, 66) Zur Berechnung der Bandpassfilter wird die Fourier Analyse verwendet.

Fourier Analyse

Die EEG Daten werden in zeitlicher Abfolge aufgezeichnet. In der typischen Darstellung der Daten, wird auf der horizontalen Achse die Zeit abgetragen und auf der vertikalen Achse die Messwerte (Volt). Diese Ansicht wird als Zeitdomäne bezeichnet und ist in Abbildung 8 Darstellung der Zeit- und Frequenz-Domäne durch die rote Linie dargestellt. Um die Informationen in Bezug auf die Frequenzen darstellen zu können, kann mittels diskreter Fourier Transformation die Frequenzdomäne berechnet werden. Diese ist in blau in derselben Abbildung dargestellt. In dieser Darstellung ist die Zeit nur noch indirekt enthalten, als Teil der Frequenz. Bei EEG Daten handelt es sich jedoch nicht um kontinuierlich gleichbleibende Schwingungen. Daher sollten nur kurze Zeitabschnitte transformiert werden und nicht längere Perioden. (Cohen 2014, 196)




Abbildung 8 Darstellung der Zeit- und Frequenz-Domäne (squidarth 2018)

3 Brain Computer Interfaces (BCI)

Die zu Deutsch auch als “Gehirn Computer Schnittstellen” bezeichneten Brain Computer Interfaces (BCI) sind Schnittstellen zwischen einem Menschen respektiv dessen Gehirn und einem Computer. Dabei werden zur Kommunikation weder Tasteneingaben, noch Computermousebewegungen verwendet. Vielmehr wird die Aktivität des Gehirns durch Ableitung elektrischer Signale gemessen und durch den Computer analysiert. Dieser kann durch Filterung und Mustererkennung bestimmte Signale weiterverarbeiten und gegebenenfalls das entsprechende Kommando ausführen. Als einfachste und günstigste Variante eignet sich dazu die Elektroenzephalographie (EEG).

Seit der Entdeckung der Elektroenzephalographie wurden neben diagnostischen Fragestellungen und Forschungsgebieten auch die Möglichkeiten einer weiteren Kommunikationsmöglichkeit für den Menschen in Betracht gezogen. Dies auch aufgrund von Krankheiten, wie der Amyotrophen Lateralsklerose (ALS), eine unheilbare, degenerative Erkrankung der Motorik Nervenbahnen. Dies bedeutet im Endstadium ein Verlust jeglicher Muskelfunktion, da die Muskeln nicht mehr angeregt werden können. Die sensorischen Nervenbahnen sind davon jedoch fast nicht betroffen. Das heisst Sehen (wenn auch ohne Augenbewegungen und Akkommodation (Scharfstellen auf die Nähe)) und Hören bleiben möglich. Durch ein Brain Computer Interface kann der Patientin und dem Patienten wieder eine Stimme geben werden. Von einer massiv eingeschränkten Handlungsfähigkeit sind auch Tetraplegiker betroffen. Auch wenn in diesem Fall durch die Stimme sowie Kopfbewegungen und die Mimik noch ein grosser Teil an Kommunikation möglich ist. Auch hier bietet ein BCI Möglichkeiten die Handlungsfähigkeit wieder zu vergrössern.

Neben diesen unterstützenden Anwendungen ist es natürlich auch spannend mittels dieser Technologie die menschlichen Fähigkeiten wie die Aufmerksamkeit, die Konzentration oder Meditationszustände zu erforschen und zu trainieren. Steuerungsmöglichkeiten daraus abzuleiten, ist dabei also nur ein Aspekt, welcher je nach Zielgruppe ganz unterschiedlich wichtig ist. (Birbaumer 2006)

3.1 OpenBCI

OpenBCI ist eine Community rund um das Open Source-Projekt, welches ein Brain Computer Interface (BCI) offen zugänglich macht. Eine grosse Community bestehend aus ForscherInnen, WissenschaftlerInnen, IngenieurInnen, MacherInnen und KünstlerInnen und wer auch immer daran teilhaben will, engagiert sich für die Verfügbarkeit und Weiterentwicklung der Hardware und Software, welche es möglich machen, mittels kleinem Budget die elektronischen Signale des Körpers insbesondere des Gehirns zu messen. Ihre Motivation liegt im Vorantreiben einer ethischen Innovation der Technologie von Mensch-Maschine-Schnittstellen. OpenBCI bietet die Hardware sowie verschiedene Software Produkte zum Auslesen der Rohdaten an. (OpenBCI 2018)

3.1.1 Hardware OpenBCI

Verschiedene Sets von Hardware, insbesondere das Headset mit den Boards sind zu erwerben. Das Headset gibt es als "Print-yourself"-Variante. Das heisst, es besteht die Möglichkeit, die 3D-Druck Elemente selber zu drucken. Somit müssen nur die Elektroden inklusive Kabel erworben werden. Komplett aufgebaute Headsets sind ebenfalls erhältlich. Ein komplett aufgebautes Headset inklusive der Elektroden (8-channels) kostet zur Zeit dieser Arbeit \$799.99. Es bestehen inzwischen verschiedene Versionen des Headsets. Das aktuellste Headset ("Mark IV") bietet 35 mögliche Platzierungen von Elektroden an (siehe Abbildung 9). Neben dem Headset ist auch ein Stirnband (EEG Headband Kit) erhältlich, an welchem sich Elektroden platzieren lassen. Im Kit enthalten sind fünf Elektroden.




Abbildung 9 OpenBCI Headset

Das Headset "Mark III" von OpenBCI welches in dieser Arbeit verwendet wurde hat 21 Orte, an denen Elektroden platziert werden können. Die möglichen Positionen aus dem 10-20 System sind in blau eingezeichnet in Abbildung 10. Als zwei zusätzliche Positionen sind die beiden Ohrpositionen A1, A2 blau markiert. Aus den verschiedenen Positionen des Headsets können also eine Vielzahl von Kombinationsmöglichkeiten für die acht (oder 16) Kanäle zusammengestellt werden. Dies ermöglicht verschiedene Anwendungen resp. Analysen. Dabei wird der hauptsächliche Unterschied zu klinisch professionellem Equipment sichtbar. Dort werden 64 oder sogar bis zu 256 Elektroden verwendet, was eine deutlich grössere Datenlage ergibt. (OpenBCI 2018)




Abbildung 10 10-20-System, blau markiert die OpenBCI Headset Positionen

OpenBCI Boards

Als Herzstück der OpenBCI Hardware gelten die Boards (Leiterplatten). Es gibt verschiedene Varianten und Versionen. Die Basis Varianten bieten acht Kanäle, mittels Aufsätzen können jedoch auch 16-Kanal EEG realisiert werden. Da die Entwicklung laufend vorangetrieben wird, verzichten wir hier auf eine detaillierte Aufzählung aller Möglichkeiten und verweisen auf den Hersteller (OpenBCI 2018). Im Folgenden wird das in dieser Arbeit verwendete Board beschrieben.

Das Cyton Board, ist vom Aufbau her den bekannten Arduino Boards ähnlich. Es hat die Form eines regelmässigen Oktagons (siehe Abbildung 11). Neben einem Beschleunigungssensor, einer microSD-Karten Aufnahme und dem Batterieanschluss beherbergt das Board einen Analog-Digital-Converter

(ADC) von Texas Instruments (ADS1299). Zur kabellosen Übermittlung der Daten ist ein Bluetooth Chip (RFduino BLE radio) eingebaut, welcher sich mit dem passenden USB Dongle verbindet. Ebenfalls erhältlich ist ein WiFi Aufsatz zur Datenübertragung. (OpenBCI 2018)




Abbildung 11 OpenBCI Cyton Board aus (OpenBCI 2018)

Neben den zwei Referenz Eingängen stehen acht analoge Kanäle zur Verfügung. Dazu finden sich auf dem Board die Pins mit den Beschriftungen N1P bis N8P. Eine mögliche Belegung der Pins mit zugewiesenen Elektrodenpositionen aus dem 10-20-System ist in Tabelle 2 dargestellt. Der SRB Pin ist die "default reference", mit dem die anderen Kanäle verglichen werden. Der Bias ist der Erdungspin (Ground pin), der zusätzlich auch bereits gewisse Störungssignale aus dem Signal entfernt. Die Kosten belaufen sich zum Zeitpunkt der Arbeit auf \$499.99. (OpenBCI 2018)

SRB	N1P	N2P	N3P	N4P	N5P	N6P	N7P	N8P	BIAS
	1	2	3	4	5	6	7	8	
weisses Kabel	graues Kabel	violettes Kabel	blaues Kabel	grünes Kabel	gelbes Kabel	oranges Kabel	rotes Kabel	braunes Kabel	schwarzes Kabel
linkes Ohr	Fp2	Fp1	C3	C4	Cz	T6	O1	O2	rechtes Ohr

Tabelle 2 Beispiel einer möglichen Belegung (Kabelfarben, 10-20-System Positionen)

3.1.2 Software OpenBCI

Die Community von OpenBCI arbeitet an verschiedenen Softwareprojekten und stellt folgende Artefakte zur Verfügung (Stand 4.2018).

Eine ausgereifte GUI-Lösung um die Signale auszulesen und in verschiedenster Form darzustellen, wird für Mac, Windows und Linux angeboten. Das GUI ist als Dashboard aufgebaut mit verschiedenen Widgets. Der Quellcode dazu liegt offen und basiert auf Processing („Processing.org“ 2018). Eine Vorlage für ein "Custom-Widget" ist bereits vorhanden. Dadurch lässt sich diese Anwendung auch modular weiterentwickeln.

Basierend auf verschiedenen Programmiersprachen und Umgebungen bestehen weitere Projekte, welche alle auf Github frei verfügbar sind. Zum Verarbeiten der Rohdaten aus dem EEG ist eine Basisimplementierung in Python, node.js, Matlab und wie bereits erwähnt mit Processing/Java vorhanden. Die aktuellen sowie die vorgängigen Firmware Versionen für die beiden Boards sowie die 3D-Druckdaten für das Headset sind ebenfalls auffindbar. („OpenBCI GitHub“ 2018)

3.2 EEG-Hardware

EEG-Hardware gibt es in ganz unterschiedlichen Preissegmenten. Professionelle Geräte, welche im klinischen Umfeld eingesetzt werden haben bis zu 256 Elektroden und kosten über \$25'000. Im mittleren Preissegment unterhalb \$25'000 bis hinunter zu \$1000 finden sich ebenfalls viele Anbieter. Diese Geräte haben zwischen 7-64 Elektroden, in den meisten Fällen sind es 24. Im Bereich der Low-Cost Geräte wie das von OpenBCI bieten auch andere Anbieter ihre Produkte an. (Farnsworth und Ph.D. 2017) Im Folgenden werden ausgewählte Produkte einiger Anbieter aus der untersten Preisklasse aufgelistet, um eine Übersicht und einen Vergleich zu dem in dieser Arbeit verwendeten Gerät zu ermöglichen. Da bereits im Verlaufe dieser Arbeit wieder neue Produkte auf den Markt kamen, kann hier kein Anspruch auf Vollständigkeit erhoben werden.

3.2.1 Muse

Muse ist ein EEG Stirnband das von der kanadischen Firma Interaxon entwickelt wurde. Das Muse Stirnband lässt sich mit einer Meditations-App verbinden und gibt den Nutzenden Echtzeit-Feedback über ihre Gehirnaktivität während des Meditierens. Das Muse Stirnband verfügt über 7 Sensoren. Zwei Sensoren an der Stirn, zwei hinter den Ohren und drei Referenzkontakte. Das Stirnband kostet €249. Muse ist nicht Open Source, bietet jedoch eine SDK („SDK



Abbildung 12 Muse

Muse“ 2018) an, mit der auf die EEG Daten zugegriffen werden kann. Damit können eigene native Apps für Muse entwickelt werden. Für die nichtkommerzielle Verwendung kann das SDK gratis verwendet werden. Für eine kommerzielle Nutzung wird eine kostenpflichtige Lizenz benötigt. („InteraXon Muse - Meditationsassistent - MindTecStore“ 2018)

3.2.2 Emotiv

Das Unternehmen Emotiv bietet drei verschiedene Headsets an für unterschiedliche Zielgruppen. Das neueste Produkt "EPOC Flex" wurde im Verlauf dieser Arbeit erst lanciert. Bereits länger erhältlich sind die Modelle "EPOC" und "Insight". Emotiv stellt eine umfassende Developer-Umgebung zur Verfügung namens "Cortex". Es gibt verschiedene Lizenzmodelle. Nicht-kommerzielle Verwendungen sind möglich mit der kostenfreien SDK. Die Rohdaten des Headsets sind jedoch verschlüsselt. Es ist somit nicht möglich, direkt auf die EEG Daten zuzugreifen, ohne die Verwendung der kostenpflichtigen Developer SDK. Das Erstellen von kommerziellen Apps und Games benötigt ebenfalls eine kostenpflichtige Lizenz. (Emotiv Cortex 2018)

Emotiv EPOC Flex

Das Emotiv EPOC Flex ist als Stoffkapuze konzipiert, an welcher sich bis zu 32 Elektroden befestigen lassen. Als neuestes Produkt von Emotiv bietet es einen guten Tragekomfort für die ProbandInnen. Durch die höhere Anzahl an Elektroden, als die gängigen low-cost EEG Headsets, liegt dieses Produkt zwischen klinischen Geräten und DIY-Hackerware. Der Preis ist jedoch mit \$2099 ebenfalls deutlich höher als gewohnt. („EPOC Flex Gel Sensor Kit“ 2018)



Abbildung 13 Emotiv EPOC Flex

Emotiv EPOC+

Emotiv Epoc+ wurde kurz nach seiner Veröffentlichung von Tan Le (CEO von Emotiv) an der TEDGlobal 2010 in Oxford vorgestellt. (Le 2018) Bei der Live Demo wurde vorgeführt, wie ein Träger des Headsets, durch vorangehendes Trainieren eines Machine Learning Algorithmus, ein virtuelles Objekt, allein mit Konzentration auf die Bewegung des Objekts, bewegt. Das Emotiv Epoc+ hat 14 Sensoren und 2 Referenzkontakte und kostet \$799. („EMOTIV EPOC+ 14 Channel Mobile EEG“ 2018)



Abbildung 14 Emotiv Epoc+

Emotiv Insight

Das Emotiv Insight ist das einfachste Modell der drei Emotiv Geräte. Es besitzt fünf Sensoren und zwei Referenzkontakte. Es ist auch das günstigste Modell mit einem Preis von \$299. („EMOTIV Insight 5 Channel Mobile EEG“ 2018)

3.2.3 NeuroSky

NeuroSky MindWave Mobile 2 ist ein preiswertes (\$99) EEG Headset mit einem einzelnen EEG Sensor und einer Referenzelektrode (MindWave Mobile 2 2018). Es unterstützt verschiedene Meditations- und Konzentrations-Apps. Im eigenen App Store können verschiedene Programme bezogen werden („Neurosky Apps“ 2018).

Mit den kostenlosen Developer Tools von Neurosky können eigene Apps entwickelt werden. Es sind verschiedene Versionen erhältlich für Android, iOS, Mac und Windows. Diese SDKs lassen zwar keinen Zugriff auf die Rohdaten zu, aber ermöglichen es, spezifische Analysen zu verwenden. Dies sind Attention, Meditation, Eye Blink Detection und BandPower. Es existiert eine kostenpflichtige (\$499.99) "Research Tools"-Software mit Zugang zu den Rohdaten. (Neurosky 2018)



Abbildung 15 NeuroSky MindWave Mobile 2

3.3 EEG-Hardware Gegenüberstellung

Um zukünftigen Projekten eine Entscheidungshilfe zu geben, wurden die Daten, der hier vorgestellten EEG-Hardware in einer Entscheidungsmatrix zusammengestellt. Es ist nochmals darauf hinzuweisen, dass sich laufend neue Möglichkeiten ergeben. Eine erneute Recherche zu erhältlichen Gerätschaften in einem neuen Projekt ist unabdingbar.

	Anzahl Kanäle	Verschiedene 10-20-Positionen konfigurierbar	Open Source SDK (inkl. Rohdaten)	SDK kostenfrei eingeschränkte Funktionalität	SDK Rohdaten kostenpflichtig	App-Store	Preis (US-Dollar)
OpenBCI Cyton	8	X	X				499.99
OpenBCI Cyton with Daisy	16	X	X				949.99
Muse	7			X	X		290.00
Emotiv Flex	32			X	X		2099.00
Emotiv Epoc+	14			X	X		799.00
Emotiv Insight	5			X	X		299.00
Neurosky Mindwave Mobile 2	1			X	X	X	99.00

4 Experimental Aufbau

In diesem Kapitel werden die verwendeten Technologien, sowie der Grundaufbau des Projektes beschrieben. Die entwickelten Steuerungskonzepte in Kapitel 5 basieren alle auf dieser Basis Implementierung. Die verwendete BCI-Hardware wird im Kapitel 4.1 beschrieben. Im Kapitel 4.2 wird die in diesem Projekt verwendete Software beschrieben. Der Aufbau des Musikplayers findet sich in Kapitel 4.3. Aspekte der User Experience sind in Kapitel 4.4 aufgeführt.

Die zukünftige Weiterentwicklung des Projektes ist erwünscht, deshalb werden die Code Artefakte als Open Source zur Verfügung gestellt. Der Quellcode ist in folgendem Github Repository hinterlegt https://github.com/Nottaris/OpenBCI_NodeJS_IP6 (Nottaris 2017) Um eine Vorstellung erhalten zu können, wie das Hardware Setup in der Anwendung aussieht, wurde ein Demo Video erstellt. (Widmer, Job 2018)

4.1 Hardware

Für dieses Projekt stand ein OpenBCI Hardware Kit zur Verfügung. Dieses beinhaltet das OpenBCI Cyton Board mit 8 Kanälen. Die weitere Verwendung als Open Source Projekt wird auch durch die Verwendung von Open Source Hardware unterstützt. Durch die variable Elektrodenpositionierung und den Zugriff auf die Rohdaten sind verschiedene Konzepte möglich. Eine detaillierte Beschreibung der Hardware befindet sich in Kapitel 3.1.1. Für die unterschiedlichen Steuerungen wurden jeweils andere Elektrodenpositionen verwendet, die entsprechenden Positionierungen werden in den jeweiligen Experimenten beschrieben. Der USB Dongle zur kabellosen Verbindung konnte an einem beliebigen USB Port angeschlossen werden.

4.2 Software

Der Server wurde auf node.js (Node js Foundation 2018) aufgebaut. Der Server stellt die Verbindung zwischen OpenBCI Board und Client (Musikplayer) her und verarbeitet die EEG Daten.

Der OpenBCI Cyton Treiber kann als Node Package installiert werden. Dadurch kann eine Verbindung vom Server via seriellen Port mit dem Board aufgebaut werden und die EEG Daten können gestreamt werden. Der serielle Port kommuniziert über Bluetooth via USB Dongle mit dem Board. Der USB Dongle wiederum ist mit dem Server verbunden.

In Listing 1 ist der Code aufgeführt, welcher aufzeigt wie eine Verbindung mit dem OpenBCI Board aufgebaut wird und wie die Samples verarbeitet werden können. Die detaillierten Board Konfigurationsmöglichkeiten, wie z.B. das Aktivieren und Deaktivieren von einzelnen Channels, sind im OpenBCI Git Repository beschreiben. (OpenBCI_NodeJS_Cyton 2017)

```

const Cyton = require('openbci-cyton');
const ourBoard = new Cyton(
  simulate: false // Full functionality, just mock data if set to true
);
ourBoard.connect(portName) // Port name is a serial port name`
.then(() => {
  ourBoard.streamStart();
  ourBoard.on('sample', (sample) => {
    /** Work with sample */
    for (let i = 0; i < ourBoard.numberOfChannels(); i++) {
      console.log("Channel " + (i + 1) + ": " + sample.channelData[i].toFixed(8) + " Volts.");
      // prints to the console
      // "Channel 1: 0.00001987 Volts."
      // "Channel 2: 0.00002255 Volts."
      // ...
    }
  });
});

```

Listing 1 Verbindung mit OpenBCI Board herstellen und Samples streamen

Die Beweggründe für die Verwendung von node.js war der Anspruch an eine möglichst plattformunabhängige Software, welche die Einbindung von browserbasierten Anwendungen für den Musikplayer vereinfachen. Einer späteren Portierung auf mobile Geräte, ist dadurch leicht möglich. Durch die Verwendung des Cyton Boards Treibers als Node Package wird sichergestellt, dass Treiberupdates einfach eingespielt werden können. Bei der Verwendung eines anderen OpenBCI Boards kann der Treiber ausgetauscht werden. Die Anwendung ist durch die Verwendung von node.js skalierbar und einfach erweiterbar, dadurch kann sie individuell auf die Bedürfnisse der einzelnen Steuerungskonzepte angepasst werden.

Für die Auswertung der EEG Daten, bei den komplexeren Steuerungen P300 und Motor Imagery (Mind) wurden zusätzlich Python v3.6 (Python 2018) Scripts verwendet. Für die Auswertungen mit Machine Learning wurde die Python Library Scikit-learn v0.19.1 (scikit-learn.org 2018) verwendet. Die in node.js implementierten Funktionen wurden durch das Testframework mocha.js (Mochajs 2018) getestet.

Als Web Applikations Framework für den Musikplayer wird React (reactjs.org 2018) verwendet. Damit der Musikplayer mit dem Server, der die EEG Daten analysiert, kommunizieren kann, werden Websockets verwendet. Das node.js Package socket.io (Socket.IO 2018) bietet dazu die entsprechende Programmierschnittstelle (API). Die Art der Implementierung ist etwas unterschiedlich, je nach verwendetem Steuerungskonzept. Diese werden in Kapitel 5 detailliert beschrieben.

4.3 Musikplayer

Die hauptsächlichen Funktionen eines Musikplayers wurden durch die folgenden Kommandos umgesetzt. Diese lassen sich je nach Bedarf erweitern.

Play	Starten der Wiedergabe
Pause	Pausieren (Stoppen) der Wiedergabe
Next	Das nächste Stück wiedergeben.
Prev	Das vorherige Stück wiedergeben.
VolUp	Die Lautstärke erhöhen.
VolDown	Die Lautstärke reduzieren.

Zur Vereinfachung für den Anwender wurden die beiden Kommandos Play und Pause auf eine Schaltfläche gelegt („playpause“). Einerseits ist abhängig davon, ob bereits Musik spielt oder nicht, sowieso immer nur das eine Kommando sinnvoll, andererseits reduziert sich dadurch die Anzahl an möglichen Optionen, was eine Vereinfachung darstellt.

Zur Darstellung der verschiedenen Kommandos wurden Icons (siehe Abbildung 16) aus der Sammlung „Font Awesome“ („Font Awesome 5 Icons“ 2018) verwendet. Diese lassen sich einfach skalieren und sind dank der starken Verbreitung allgemein bekannt. Auf textuelle Bezeichnungen wurde bewusst verzichtet, da es sich um naheliegende Kommandos handelt. Ebenso entfällt damit der Bedarf einer Anpassung an verschiedene Sprachen.

Die drei verschiedenen Benutzeroberflächen für die drei Steuerungskonzepte lassen sich durch ein Dropdown im Titel des Musikplayers auswählen (siehe Abbildung 16 Musikplayer GUI Blink).

Erlaubt man dem Browser die vorhandene Kamera zu verwenden, so lässt sich die Steuerung im GUI Blink automatisch aktivieren und deaktivieren. Sobald ein Gesicht erkannt wird, ist die Steuerung aktiv, wendet man das Gesicht ab oder verdeckt die Kamera, so ist die Steuerung deaktiviert (siehe Kapitel 4.4 Aktivierungsmöglichkeiten einer Steuerung).

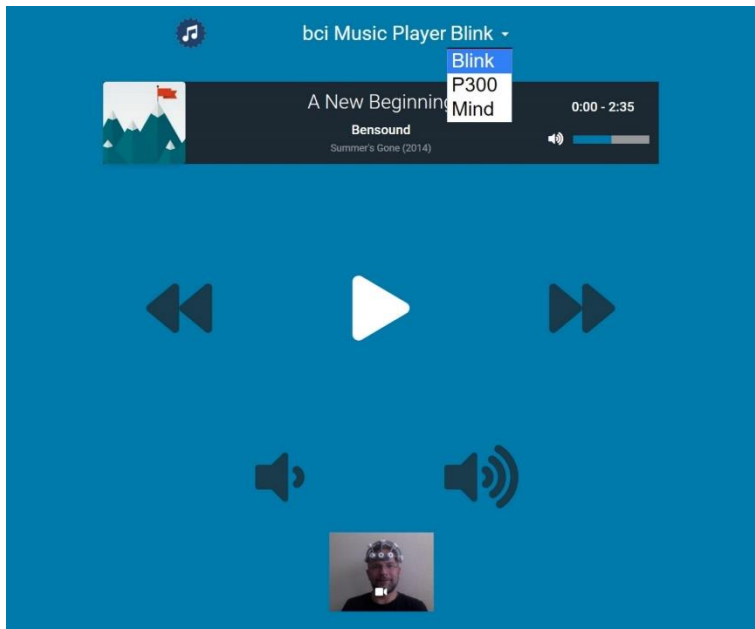


Abbildung 16 Musikplayer GUI Blink mit abwechselnd weiss aufleuchtenden Kommandos

Gestaltung und Farbwahl

Der Musikplayer wurde möglichst einfach und übersichtlich gestaltet. Die beiden Oberflächen "Blink" und "Mind" haben einen blauen Hintergrund. Für das Steuerungskonzept P300 wurde der Hintergrund bewusst schwarz gewählt. Dabei soll das Umfeld möglichst dezent erscheinen und das aufleuchtende Kommando, entsprechend in starkem Kontrast hell hervorstechen. Die Grösse der Steuerungselemente wurde auf Desktop Monitore ausgelegt. Auf eine Anwendung für Smartphones wurde in dieser Arbeit verzichtet.

Logo

Die OpenBCI Community verwendet ein Zahnrad mit einem abstrahierten Gehirn oder Text in der Mitte des Zahnrads als Logo. Für unser Projekt resp. den Musikplayer wurde ein Logo analog dazu entwickelt, welches eine Musiknote enthält (siehe Titelblatt).

4.4 User Experience

Aktivierungsmöglichkeiten einer Steuerung

Eine automatische Aktivierung und Deaktivierung der Steuerung des Musikplayers wurde implementiert. Dies wurde erreicht durch die Einbindung der Kamera. Die Steuerung ist nur aktiv, so lange die Anwendenden auf den Bildschirm beziehungsweise in die Kamera schauen. Somit kann man ungewollte Kommandoabgaben verhindern. Arbeitet man am beispielsweise am Laptop und will die Steuerung unterbinden, kann einfach die Kamera deaktiviert werden, entweder durch Zudecken der Öffnung oder via Softwareeinstellung. Eine Umsetzung ist mittels tracking.js im Web problemlos möglich, wie das Beispiel eines „schüchternen“ Sortieralgorithmus („Shy-Sort.Html“ 2018) zeigt. Dieser sortiert das Array nur richtig, wenn „ihm“ niemand zuschaut. Blickt man in die Kamera, so werden die Zahlen zufällig verwürfelt.

Diese Option besteht für alle in dieser Arbeit beschriebenen Steuerungskonzepte. Umgesetzt wurde dies für die Steuerung durch das Blinzeln, bei der die Anwendenden den Bildschirm zur Steuerung sowieso betrachten müssen. Die automatische Aktivierung und Deaktivierung der Steuerung durch die Kamera kann durch ein Klicken auf das kleine Kameraicon ein- und ausgeschaltet werden. Nach einem Umschalten der GUI Oberfläche im Musikplayer, muss zur erneuten Aktivierung der Webcam die Seite neu geladen werden.

Für das Steuerungskonzept Motor Imagery (Mind) ist nach erfolgreichem Training, eine Bedienung auch ohne das Betrachten des Bildschirms möglich. Hier wäre dieser Ansatz also bedingt geeignet. Als Vorteil würden so bestimmt keine ungewollten Kommandos abgesetzt, dafür müsste zur Steuerung dann doch wieder auf den Monitor geschaut werden, was einen Vorteil dieses Steuerungskonzepts wieder aufheben würde.

Voice

Damit die Anwendenden die Anweisungen nicht auf dem Bildschirm lesen müssen, werden beim Mind GUI die Informationen auch als Voice ausgegeben. Die Verwendung von responsivevoice.js („ResponsiveVoice Text To Speech“ 2018) ist konfigurierbar. Es lassen sich verschiedene Sprachen sowie das Geschlecht der virtuellen Stimme bestimmen.

5 Steuerungskonzepte

In diesem Kapitel werden die unterschiedlichen Steuerungskonzepte für das Bedienen des Musikplayers mittels OpenBCI beschrieben. Als erstes wurde die Steuerung durch ein bewusstes Blinzeln ausgearbeitet, da ein kurzes Schliessen der Augen relativ einfach im EEG erkannt werden kann. Dies ermöglicht eine einfache Interaktion als erste Variante einer Steuerung.

Als zweite Variante wurde die Steuerung mit evozierten Potentialen (P300 Welle) umgesetzt. Das Steuerungskonzept funktioniert ähnlich wie bei einem P300 Speller. Die verschiedenen Bedienbutton leuchten abwechselnd auf und die Anwendenden konzentrieren sich auf den Button dessen Funktion sie ausführen möchten.

Das dritte Steuerungskonzept basiert auf einer anfänglichen Trainingsphase, bei welcher die Anwendenden sich auf die gegebenen Kommandos konzentrieren sollen. Dabei werden die Hirnströme aufgezeichnet. Mittels Machine Learning wird versucht, die fünf verschiedenen Kommandos zu unterscheiden. Nach der Trainingsphase, beim Benutzen des Musikplayers, sollen diese wiedererkannt werden.

5.1 Steuerung durch Blinzeln

Bei dieser Steuerung werden die Kommandos durch ein bewusstes Blinzeln ausgelöst. Der regelmässige Lidschlag, welcher Synonym ist mit dem Begriff “Blinzeln”, wird rund 10-mal pro Minute ausgeführt. (Sachsenweger 1994, 37)

Dieses unbewusste und häufige Blinzeln eignet sich nicht für eine Steuerung. Hier wird daher unter dem Begriff “Blinzeln” das bewusste Schliessen der Augen für einen kurzen Moment verstanden. Dieses bewusste und kontrollierte Blinzeln ist einfach auszuführen für die Anwendenden und ermögliche eine klare Kommandoauslösung. Dieses Steuerungskonzept setzt voraus, dass die Anwendenden fähig sind, ihre Mimik zu kontrollieren.

5.1.1 Vorgehen Blinzeln

Bei der Umsetzung der Steuerung wurde als erstes im OpenBCI GUI unterschiedliche Arten des Blinzeln aufgezeichnet (siehe Kapitel 5.1.4, Experiment 1), dadurch konnte evaluiert werden, wie ein Blinzeln im EEG ausschlägt und wie gross die Abweichungen zwischen der Baseline und einem bewussten Blinzeln sind. Auch konnte untersucht werden, wie sich einfaches Blinzeln, doppeltes Blinzeln oder Zwinkern im EEG unterscheiden. In einem zweiten Schritt wurde ein Algorithmus erarbeitet, der das Blinzeln in den Live-Daten des EEG erkennt und einen entsprechenden Event auslöst, die eine Interaktion mit dem Computer ermöglicht. In einem dritten Schritt wurden Unittests mit Mocha (Mochajs 2018) implementiert, mit denen unterschiedliche Werte für die Klassifizierung getestet werden konnten.

5.1.2 Umsetzung Blinzeln

Für die Steuerung durch Blinzeln werden alle Kommandos im React Player mit Symbolen dargestellt (siehe Abbildung 16 Musikplayer GUI Blink). Die Schaltflächen iterieren in kurzen Zeitintervallen und signalisieren durch ein Aufleuchten dem Nutzer bzw. der Nutzerin, welches Kommando gerade "aktiv" ist. Mit einem bewussten Blinzeln kann das aktuelle Kommando ausgeführt werden (im Weiteren "execute Event"). Das Aufleuchten der Symbole (im Weiteren "flash Event") wird vom Server per socket.io gesteuert (siehe Abbildung 17). Der Server sendet ein Event mit dem Kommando, das aufleuchten soll, an den Client. Nach jedem flash Event wertet der Server die EEG Daten aus (siehe Kapitel 5.1.3 Klassifizierung Blinzeln). Wird aus diesen Daten ein Blinzeln erkannt, wird dem Player ein execute Event gesendet mit dem auszuführenden Kommando. Der Musikplayer führt das Kommando nun aus. Dies wird signalisiert durch ein buntes Aufleuchten des entsprechenden Icons. Die flash und execute Events wurden im Sinne eines "Command pattern" generisch aufgebaut, dadurch kann der Musikplayer beliebig um neue Funktionen erweitert werden.

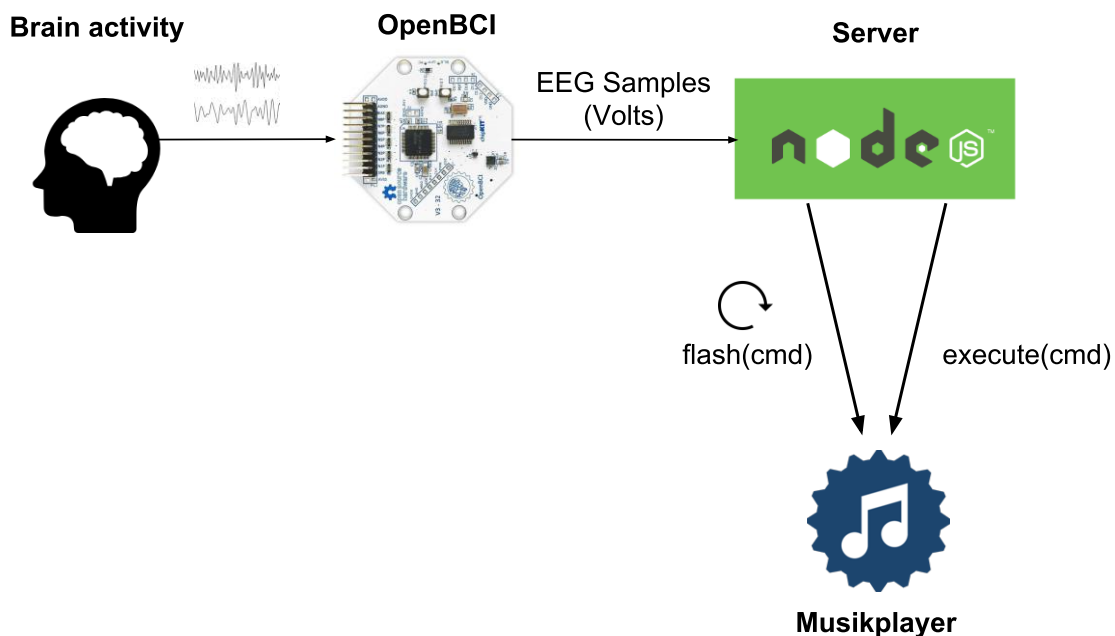


Abbildung 17 Schema Steuerung durch Blinzeln

5.1.3 Klassifizierung Blinzeln

Da bewusstes Blinzeln starke negative Ausschläge verursacht, kann dies relativ einfach erkannt werden. Die negativen Ausschläge sind in den Rohdaten gut sichtbar (siehe rote Kurve in Abbildung 18).

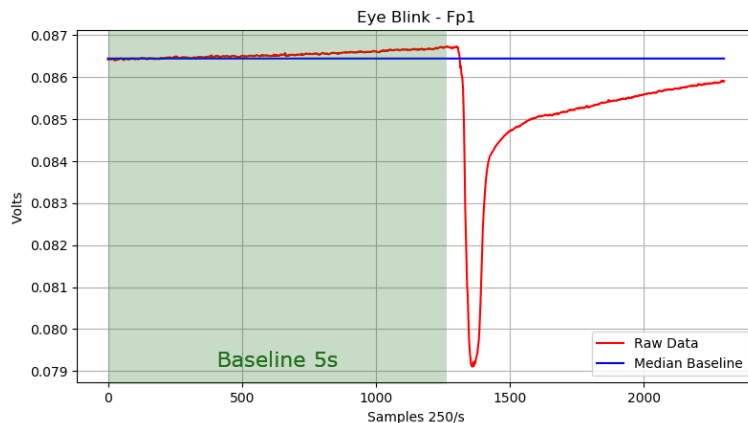


Abbildung 18 Blinzeln in Rohdaten

Da ein Blinzeln rund 300 ms (Lang 2014) dauert, ist es nicht notwendig jedes Sample (alle 4 ms) einzeln auszuwerten, daher wurden jeweils zehn Samples zu einem Median zusammengefasst. Das Blinzeln wird erkannt indem dieser aktuelle Wert mit der Baseline verglichen wird. Als Baseline wird jeweils der Median der letzten fünf Sekunden (siehe Abbildung 18) vor dem aktuellen Wert benutzt. Hierbei wird der Median verwendet, anstatt der Durchschnitt, um eventuelle Ausreisser nicht zu berücksichtigen (Cohen 2014, 227). Da sich die EEG Daten während einer Messung mit der Zeit leicht verändern können, wird die Baseline immer auf die letzten fünf Sekunden bezogen und nicht am Anfang des Experiments bestimmt. Vom Median wird die dreifache Standardabweichung subtrahiert. Liegt der aktuelle Wert noch tiefer, wird dies als Blinzeln klassifiziert.

Eine weitere Möglichkeit zur genauen Detektion des Blinzeln stellt die Anwendung eines Bandpassfilters dar (siehe Kapitel 2.4.6 Frequenzfilter). In der Abbildung 19 sind in den 1- 30 Hz Bandpass gefilterten Daten, zwei Blinzeln abgebildet. Das erste Blinzeln startet bei 300 Samples, das zweite bei 1300 Samples.




Abbildung 19 Blinzeln in Bandpass gefilterten Daten

Berechnungen

Mit folgender Berechnung wird klassifiziert, ob es sich bei den betrachteten EEG Daten (aktueller Wert), um ein Blinzeln handelt:

$$\text{Blinzeln} = \text{aktueller Wert} < (\text{Baselinemedian} - (\text{Threshold} * \text{Standardabweichung}))$$

<i>aktueller Wert:</i>	Median der letzten 10 EEG Samples
<i>Baselinemedian:</i>	Median der 5 Sekunden Baseline
<i>Standardabweichung:</i>	Wurzel der Varianz aus Baseline
<i>Threshold:</i>	Faktor um den Schwellenwert zu berechnen, der überschritten werden muss, um Ausschlag als Blinzeln zu klassifizieren

Im Experiment 2 wurden die Umsetzung getestet, in dem bewusst alle 10 s geblinzelt wurde (siehe Kapitel 5.1.4, Experiment 2). In weiteren Tests konnte analysiert werden, dass das bewusste Blinzeln auch mit einem Threshold von 0.2 bis 3.9 korrekt klassifiziert wurde. Je nach Signalqualität und Testperson variiert dieser Wert. In dieser Arbeit wurde der Threshold auf 3.0 festgelegt.

5.1.4 Experimente Blinzeln

Experiment 1 – Blinzeln visualisieren

Für dieses Experiment wurde das OpenBCI mit Channel Fp1 (N1P) und Fp2 (N2P) verwendet, mit BIAS und SRB 2 (am Ohr läppchen befestigt). Alle anderen Channel wurden deaktiviert.

Das Ziel dieses Experimentes war es, Augenbewegungen wie Blinzeln in den EEG Daten mit den OpenBCI GUI aufzuzeichnen, so dass aufgrund von diesen Daten ein geeigneter Algorithmus geschrieben werden kann, der in einem EEG Strom Blinzeln erkennen kann. Es wurden nur die Elektroden an der Position Fp1 und Fp2 verwendet, da dort die Augenbewegungen am besten sichtbar sind.

Elektroden: Fp1 (N1P), Fp2 (N2P), linkes und rechtes Ohr als Bias und Referenz

Ablauf des Experimentes: Zu den angegebenen Zeiten wurde geblinzelt, dazwischen wurden die Augen möglichst ruhig gehalten für die Baseline.

10 s	1x Blinzeln
15 s	1x Blinzeln
20 s	2x Blinzeln (doppeltes Blinzeln)
25 s	1x Rechts Zwinkern
35 s	1x Mund öffnen & schliessen

Ergebnis

Die unterschiedlichen Augenbewegungen sind deutlich in den untenstehenden Abbildungen ersichtlich. Es wurde ein Bandpassfilter 7 - 13 Hz verwendet. Oben rechts im Bild wird jeweils die verwendete vertikale Skalierung (vert Scale) angezeigt.




Abbildung 20 Bewusstes Blinzeln




Abbildung 21 Doppeltes Blinzeln




Abbildung 22 Rechts Zwinkern




Abbildung 23 Mund öffnen & schliessen

Experiment 2 – Blinzeln erkennen

In diesem Experiment soll die Steuerung mit Blinzeln getestet werden. Wenn ein Signal als bewusstes Blinzeln klassifiziert wurde, wird eine Nachricht in der Konsole ausgegeben. Zusätzlich wird ein "execute Event" an den Player geschickt, mit dem auszuführenden Kommando. Es wird die Elektrode Fz1 (N1P) verwendet, zusätzlich linkes und rechtes Ohr als Bias und Referenz

Am Board wird nur den Channel 1 benutzt, sowie bias und srb2, alle anderen Channels sollen deaktiviert werden (powerDown = true). Dies kann in der Board Konfiguration erreicht werden, durch die folgenden Codezeilen in Listing 2.

```
//channelSet(channelNumber,powerDown,gain,inputType,bias,srb2,srb1)
ourBoard.channelSet(1,false,24,'normal',true,true,false);
ourBoard.channelSet(2,true,24,'normal',true,true,false);
ourBoard.channelSet(3,true,24,'normal',true,true,false);
...
```

Listing 2 Board Konfiguration

Zum Erkennen des Blinzeln werden verschiedene Parameter verwendet, welche als Variablen zu Beginn des Scripts definiert werden. In diesem Experiment wurden folgende Einstellungen verwendet.

```
baselineLengthSec = 5;    // time in seconds for baseline
slots = 10;              // data points per slot
channel = 1;             // number of channel ( from 1 to 8 )
sampleRate = 250;        // 250Hz
```

Ergebnis

In diesem Experiment wurde bewusst alle 10 s geblinzelt. Alle Vorkommnisse eines Blinzeln wurden erfolgreich erkannt und in der Konsole ausgegeben:

```
BLINK:   value: -62673.65      at Tue Apr 24 2018 20:44:43 GMT+0200
BLINK:   value: -64804.22      at Tue Apr 24 2018 20:44:53 GMT+0200
BLINK:   value: -65709.85      at Tue Apr 24 2018 20:45:03 GMT+0200
BLINK:   value: -66006.63      at Tue Apr 24 2018 20:45:13 GMT+0200
BLINK:   value: -66143.49      at Tue Apr 24 2018 20:45:23 GMT+0200
BLINK:   value: -66466.56      at Tue Apr 24 2018 20:45:33 GMT+0200
BLINK:   value: -66374.09      at Tue Apr 24 2018 20:45:43 GMT+0200
BLINK:   value: -66031.77      at Tue Apr 24 2018 20:45:53 GMT+0200
BLINK:   value: -67126.21      at Tue Apr 24 2018 20:46:04 GMT+0200
```

5.1.5 Erkenntnisse Blinzeln

Das Steuerungskonzept Blinzeln funktioniert zuverlässig, je nach Testperson kann der Ausschlag bei einem bewussten Blinzeln jedoch unterschiedlich stark sein. Um einen allgemein gültigen Schwellenwert (threshold) für das Erkennen des Blinzeln zu definieren, müssten weitere Tests mit unterschiedlichen Testpersonen durchgeführt werden.

Die Steuerung könnte erweitert werden, indem unterschiedliche Arten von Blinzeln anders klassifiziert werden (kurze, lange, doppeltes Blinzeln). Dies würde eine komplexere Steuerung ermöglichen. In den gefilterten Daten kann gut zwischen Einfach- und Doppel-Blinzeln unterschieden werden, indem die Länge des Ausschlages ausgewertet wird (siehe Abbildung 20 und Abbildung 21). Auch die Mehrfacherkennungen desselben Blinzeln, könnte vermieden werden indem der positive Ausschlag, der auf den negativen Ausschlag folgt (siehe Abbildung 20) als Endpunkt verwendet wird. Für die unterschiedliche Klassifizierung des Blinzeln müsste ein Bandpassfiltering (7-13 Hz) verwendet werden (siehe Experiment 1 unter 5.1.4 Experimente Blinzeln).

Um mehrfach Erkennungen desselben Blinzeln bei den ungefilterten Daten zu unterbinden, werden in der aktuellen Implementierung nach dem Erkennen eines Blinzeln, die nächsten paar hundert Millisekunden übersprungen und nicht ausgewertet.

Das Bedienen eines Musikplayers durch ein Augenschliessen ist einfach zu erklären und sollte altersunabhängig problemlos anwendbar sein. Potentielle Fehlkommandoabgaben könnten durch ein Augenreiben, andere Manipulationen oder durch die Mimik entstehen. Dies wurde durch eine Aktivierung- respektive Deaktivierung der Steuerung (siehe Kapitel 4.4 Aktivierungsmöglichkeiten einer Steuerung) reduziert.

5.2 Steuerung durch evozierte Potentiale

Als vielversprechendste Variante aus der Literatur wurde die P300 gewählt als evoziertes Potential für das zweite Steuerungskonzept. Der Vorteil einer P300 basierten Steuerung wäre, dass keinerlei körperliche Bewegungen nötig sind. Jedoch wären Anwendende mit grösseren körperlichen Einschränkungen immer noch auf Unterstützung angewiesen, um das Headset in Betrieb zu nehmen.

5.2.1 P300

Für P300-basierende BCI Anwendungen, werden die Elektroden vorwiegend über dem Parietallappen positioniert, da dort die P300 Welle ersichtlich ist. Krusienski empfiehlt 8 Kanäle zu verwenden und die Elektroden auf den Positionen Fz, Cz, P3, Pz, P4, PO7, Oz, PO8 zu platzieren (Krusiensi u. a. 2006, 4).

Um die P300 Welle in den 8 Kanälen zu erkennen, müssen die Daten aufbereitet, Features extrahiert und klassifiziert werden. Lotte empfiehlt folgendes Vorgehen zur Klassifizierung von P300: 1) Bandpass Filterung des Signals auf 1 - 12 Hz 2) Downsampling vom gefilterten Signal, um die Anzahl der EEG Samples zu reduzieren 3) Aus den verbleibenden EEG Samples Feature Vektoren erstellen, die als Input für den Klassifizierer dienen. 4) Der Klassifizierer wird mit den extrahierten Features trainiert, und ordnet die Features der Klasse target (P300 Welle) oder non-target (keine P300 Welle) zu. Dies wird meist erreicht durch das Verwenden von üblichen Klassifizierern wie die Linear Discriminant Analysis (LDA) oder einer Support Vector Machine (SVM). (Lotte 2018, 19)




Abbildung 24 Typischer Prozess zur Klassifizierung von P300 (Lotte 2018, 20)

5.2.2 P300 für den Musikplayer

Die Symbole (Playpause, Next, Prev, Volup und Voldown) der verschiedenen Kommandos werden auf einem dunklen GUI dargestellt. Abwechselnd leuchtet eins der Symbole auf. Die Anwendenden versuchen sich auf das Kommando, das sie ausführen wollen, zu konzentrieren. Dazu soll auf das entsprechende Icon fokussiert werden und eventuell mitgezählt werden, wie oft es aufleuchtet. Wird dadurch, nach dem Aufleuchten des Symbols, eine P300 Welle ausgelöst, erkennt die Software dies und führt das zuvor aufblinkende Kommando aus.




Abbildung 25 Musikplayer P300 (Kommando next leuchtet auf)

5.2.3 Vorgehen P300

In einem ersten Schritt wurden verschiedene Bandpassfilter getestet um zu prüfen, welche Filterung verwendet werden soll um möglichst viel Noise zu entfernen, ohne dass die P300 Informationen verloren gehen (siehe Kapitel 5.2.6, Experiment 1). In einem zweiten Schritt wurden verschiedene Stimuli getestet, um zu untersuchen, ob stärkere P300 Wellen erzeugt werden können durch Varianz bei Intervall und Farbwahl (siehe Kapitel 5.2.6, Experiment 2). In einer ersten Version wurde geprüft, ob die P300 Welle ohne die Verwendung von Machine Learning klassifiziert werden kann, indem der Ausschlag nach 300 ms mit dem durchschnittlichen Signal verglichen wird (siehe Kapitel 5.2.6, Experiment 3). In einem letzten Schritt wurde eine Support Vektor Maschine für die Klassifizierung der P300 implementiert (siehe Kapitel 5.2.6, Experiment 4).

5.2.4 Umsetzung P300

Da die P300 Welle ein Event basiertes Ereignis ist, ist es sehr wichtig, dass die Zeitsynchronisation von Board, Server und Client übereinstimmen. Um dies sicherzustellen, wurde in der Boardkonfiguration `timeSync` (OpenBCI `node.js` time-syncing 2017) aktiviert. Dadurch wird bei jedem neuen Verbindungsaufbau des Boards die Zeit mit der Zeit des lokalen Computers synchronisiert.

In Abbildung 26 ist der schematische Ablauf der P300 Steuerung dargestellt. Zum einen werden per OpenBCI laufend die EEG Samples an den Server gesendet, gleichzeitig leuchten im Musikplayer abwechselnd die Symbole auf. Nach jedem Aufleuchten eines Symbolen schickt der Player via WebSocket ein Kommando Event mit dem aktuellen Kommando und dem aktuellen Timestamp. Der Timestamp wird vom Server verwendet, um in den EEG Daten die entsprechenden Samples für diesen Zeitpunkt zu finden. Der Server verwendet ein Python Script, um die Samples auszuwerten. Wird eine P300 Welle entdeckt, sendet der Server dem Client ein `execute` Event mit dem entsprechenden Kommando. Das Klassifizieren von P300 wird im folgenden Kapitel beschreiben.

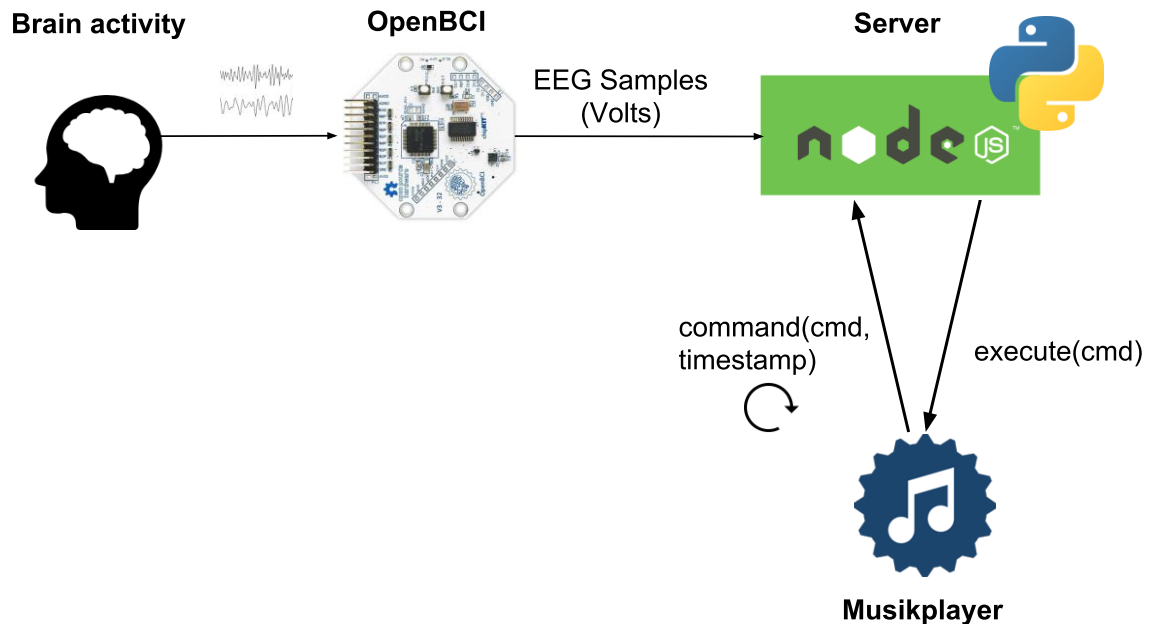


Abbildung 26 Schema Steuerung durch P300

5.2.5 Klassifizieren von P300 durch Machine Learning

In diesem Kapitel wird der schematische Ablauf beschrieben. Es wurde eine Klassifizierung durch die Verwendung von Support Vector Machines (SVM) gewählt. Es gibt einen Trainingsablauf zum Trainieren der SVM und einen Livedaten Ablauf zum Erkennen der P300 beim Bedienen des Musikplayers.

Elektroden: Fz N8P, Cz N7P, P3 N4P, Pz N5P, P4 N6P, O1 N1P, Oz N2P, O2 N3P

Trainingsablauf

1. EEG-Signale Bandpassfiltern 1 - 12 Hz
2. Signal in Daten pro Kommando aufteilen
3. Signal downsamplen
4. Feature Vektoren erstellen
 - a. $X: \text{trials} * [\text{channels} * \text{samples}]$
 - b. $y: \text{trials} * [\text{target} / \text{non-target}]$
5. Daten Trainieren nach target (mit P300) und non-target (ohne P300)
6. Support Vektoren resp. SVM Model speichern

Livedaten Auswertung Ablauf

1. Feature Vektor pro Kommando erstellen analog Trainingsablauf
2. Wahrscheinlichkeit für target / non-target anhand des trainierten SVM Model berechnen
3. Kommando mit den meisten target Klassifizierungen suchen
4. Das klassifizierte Kommando wird an den Musikplayer gesendet
5. Das Kommando wird vom Musikplayer ausgeführt

5.2.6 Experimente P300

Experiment 1 – verschiedene Bandpassfilter

Für das erste Experiment wurden die Parameter aus der Arbeit “Finally, what is the best filter for P300 detection?” (Bougrain, Saavedra, und Ranta 2012) von Bougrain, Saavedra, Ranta verwendet. Ziel dieses Experiments ist es zu prüfen welche Bandpassfilter sich gut eignen, um die P300 Welle zu klassifizieren.

Intervall Blink: 125 ms

Stimulus Highlighting: 62.5 ms

Stimulus Hintergrundfarbe der Musikplayer Steuerungsbuttons leuchten auf

Elektroden: Oz, linkes und rechtes Ohr als Referenz

Ablauf des Experimentes:

5x	Auf Play konzentrieren
5x	Auf Voldown konzentrieren
5x	Auf Next konzentrieren

Ergebnis

Die Welle bei ca. 45 Samples / 200 ms ist bei allen Filterungsvarianten deutlich zu erkennen. Der empfohlene Bandpassfilter von 0.1 - 15 Hz von Bougrain, Saavedra, Ranta scheint ein guter Kompromiss zu sein, zwischen Noise entfernen und die P300 Informationen bewahren. (siehe Abbildung 27 3. Plot)

Bei der Analyse der Daten wurde festgestellt, dass die Zeitsynchronisation des Boards nicht immer stimmt und das Board für weitere Experimente vor der Aufnahme der Daten mit der lokalen Computerzeit synchronisiert werden muss. (OpenBCI node.js time-syncing 2017)




Abbildung 27 EEG Signal verschiedene Bandpassfilter

Experiment 2 – verschiedene Stimuli

Ziel dieser Experimente ist es zu untersuchen, ob mit anderen Stimuli als im Experiment 1 ein besseres Ergebnis erreicht werden kann. Zusätzlich sollen unterschiedliche Intervalle getestet werden. Ob die Reihenfolge der leuchtenden Symbole einen Einfluss hat, wird ebenfalls diskutiert.

Elektroden: OZ linkes und rechtes Ohr als Referenz, linkes Ohr als Bias

Bandpassfilter: 0.1 - 15 Hz

Ablauf des Experimentes:

Cycle	Fokus
3x	Baseline, kein Fokus
10x	Auf Play konzentrieren

Variante A)

Stimulus: Icon Weiss auf schwarzem Hintergrund

Intervall Flash: 250 ms

Stimulus Highlighting: 125 ms




Abbildung 28 Musikplayer Variante A

Bei der Gegenüberstellung der verschiedenen Kommandos während fünf Durchläufen (Cycles) konnte bei Play (grün) erst beim fünften Durchlauf ein deutlicher Ausschlag bei 240 ms (60 Samples) erkannt werden (siehe Abbildung 29). Beim Kommando Prev hat es jedoch einen noch höheren Ausschlag. Diese könnte dadurch verursacht werden, dass das Play und Prev Symbol gleich nebeneinander im GUI positioniert sind und obwohl sich die Anwendenden nur auf Play fokussieren, sie trotzdem das Aufleuchten beider Symbole wahrnehmen.

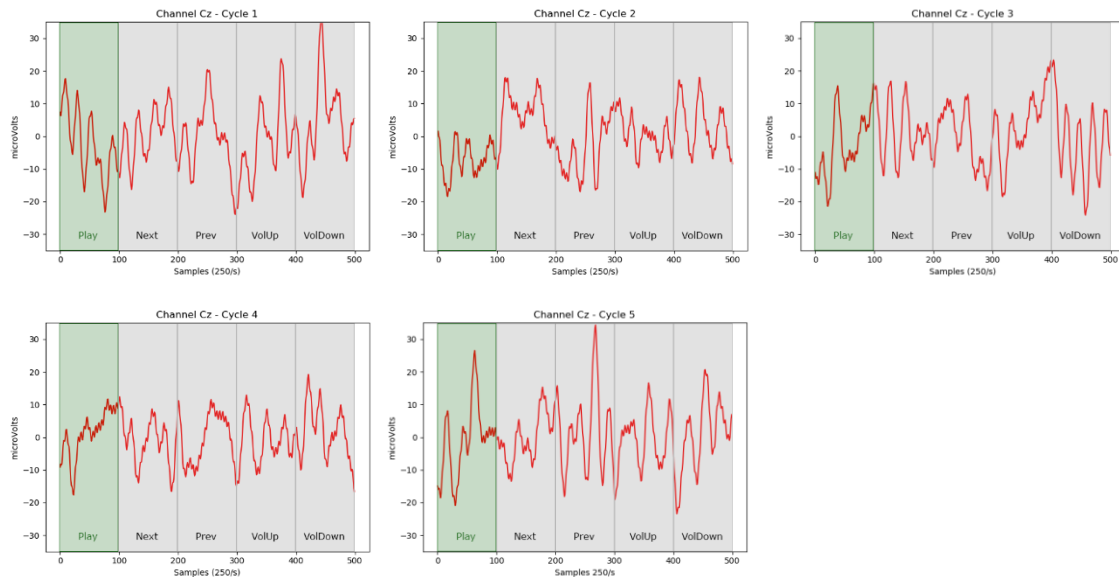


Abbildung 29 P300 Signal über mehrere Durchläufe

Variante B)

Stimulus: Weisses Icon auf buntem Hintergrund (zufällige, leuchtende Farbe) rund um das Icon

Intervall Flash: 250 ms

Stimulus Highlighting: 125 ms




Abbildung 30 Musikplayer Variante B

Durch das Aufleuchten des Hintergrundes konnte kein besseres Ergebnis erreicht werden.

Variante C)

Bei dieser Variante wurden die Kommandos durch leere “Schaltflächen” weiter auseinander platziert. Das Aufleuchten der leeren Flächen verhindert, dass die Testperson, beim Fokussieren auf das gewünschte Kommando, ein benachbartes Kommando aufleuchten sehen. Es wurden unterschiedliche Zeiten für die Stimulidarbietung getestet.

Einstellungen:

Stimulus: Weisses Icon auf buntem Hintergrund (zufällige, leuchtende Farbe) rundum Icon, zusätzliche Flächen zwischen den Kommandos, die auch aufleuchten, jedoch kein Icon zeigen.

Intervall Flash: 200 und 250 ms

Stimulus Highlighting: 63 und 125 ms




Abbildung 31 Musikplayer Variante C

Auch bei dieser Variante gab es keine deutliche Verbesserung gegenüber Variante 1 in Bezug auf die Erkennbarkeit der P300 Welle. Es ist jedoch zu beachten, dass hier nur die Daten einer Elektrode analysiert wurden. In folgenden Experimenten werden mehrere Elektroden analysiert. Das Auftreten der P300 Welle soll auch über mehrere Durchläufe (cycles) untersucht werden.

Experiment 3 – Klassifizierungsversuche ohne Machine Learning

Ziel dieses Experiments ist es, mehrere Elektroden aufzuzeichnen, um mit unterschiedlichen Signal Verarbeitungsmechanismen die P300 Welle zuverlässiger erkennen zu können. Es wird jeweils der grösste Ausschlag zwischen 200 ms (50 Samples) und 400 ms (100 Samples) nach dem Aufleuchten jedes Kommandos gesucht. Das Kommando mit dem grössten Ausschlag wird als P300 klassifiziert. Folgende Einstellungen wurden verwendet:

Intervall Flash: 450 ms

Stimulus Highlighting: 140 ms

Fokus: play

Elektroden: O1 (N4P), OZ (N1P), O2 (N6P), als Referenzelektrode, Bias rechtes Ohr

Referenzelektrode Fz

In einem ersten Versuch dieses Experimentes wurde untersucht, ob mit der Referenzelektrode an der Position Fz (Odom u. a. 2004) anstelle des Ohres ein besseres Ergebnis erreicht werden kann. Es konnte jedoch keine Verbesserung festgestellt werden.

Baseline Subtraktion

Wird pro Epoche (Auftritt des Stimulus plus 300 ms) der Durchschnittswert resp. die Baseline subtrahiert, verschiebt sich das EEG Signal zum 0 Wert. Da sich das Signal über längere Zeit verändern kann, kann mit der Subtraktion der Baseline sichergestellt werden, dass die Daten verglichen werden können. Die Erkennung der P300 Welle wird dadurch jedoch nicht erleichtert.

Vergleich von verschiedenen Messpunkten

Bei dieser Auswertung wurde der Durchschnitt verschiedener Messpunkte (Channels) berechnet, um ihn anschliessend auf P300 Wellen zu untersuchen.

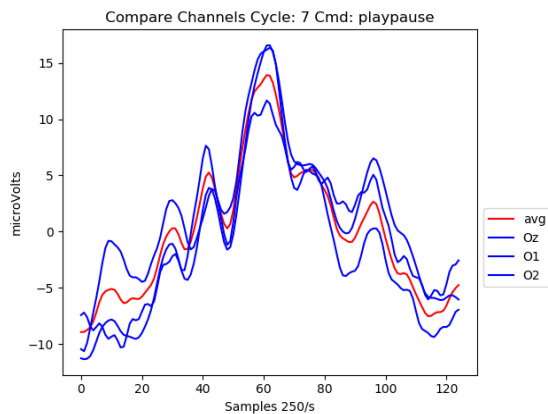


Abbildung 32 P300 Vergleich über mehrere Kanäle

In diesem Experiment wurde das Play Kommando fokussiert. In Abbildung 32 ist deutlich ersichtlich, dass bei 60 Samples / 240 ms auf allen drei Channels Oz, O1, O2 ein deutlicher Ausschlag vorhanden ist. Jedoch gibt es auch bei den nicht fokussierten Kommandos ähnliche Ausschläge, die in allen Channels auftreten. Den Durchschnitt von mehreren Messpunkten zu verwenden, scheint nicht ausreichend zu sein, um die P300 klar zu erkennen.

Klassifizierung der P300 Welle über mehrere Epochen hinweg

Bei dieser Auswertung werden fünf Durchgänge (Cycles) miteinander verglichen, dadurch sollte die P300 Welle deutlicher zu erkennen sein, wenn sie in mehreren Durchgängen auftritt. In den untenstehenden Abbildungen wird das fokussierte Kommando Play abgebildet.

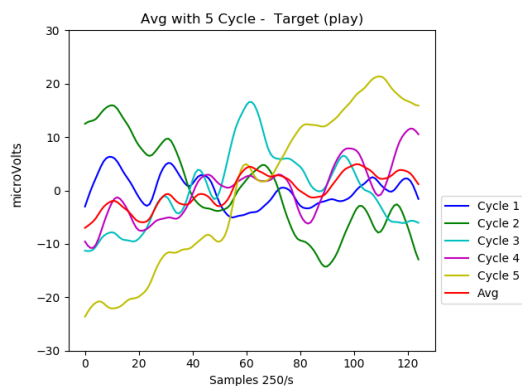


Abbildung 33 P300 Durchschnittssignal über mehrere Durchgänge

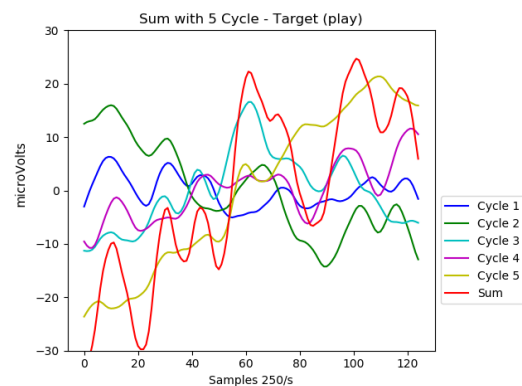


Abbildung 34 P300 Aufsummieren des Signals über mehrere Durchgänge

In der ersten Variante, wird die Durchschnittswelle für die untersuchten fünf Durchgänge pro Kommando berechnet. In der Abbildung 33 verschwindet der Cyan-farbige Ausschlag aus Cycle 3 bei 60 Samples (240 ms) durch das Berechnen des Durchschnitts (rote Linie).

In der zweiten Variante, wird das Signal über die fünf Durchgänge pro Kommando aufsummiert. Dies verstärkt, wie in der Abbildung 34 ersichtlich, den Cyan-farbigen Ausschlag aus Cycle 3 bei 60 Samples. Jedoch verstärkt das Aufsummieren des Signals (rote Linie) auch Ausschläge, welche nicht aufgrund einer P300 Welle bestehen.

Beide Varianten ergaben keine Verbesserung in Bezug auf das Erkennen der P300 Welle. Die Differenzierung einer P300 Welle vom restlichen Signal konnte nicht erreicht werden.

Experiment 4 – Klassifizierung von P300 mit SVM

Dieses Experiment orientiert sich an den Empfehlungen von Lotte (Lotte 2018). Es werden Trainings- und Testdaten aufgenommen, anschliessend soll unter der Verwendung einer Support Vector Maschine die Klassifizierung gemacht werden, ob es sich um eine P300 Welle handelt. Für die Klassifizierung wird eine Support Vector Maschine mit einem linearen Kernel verwendet.

Elektroden: Fz (N8P), Cz (N7P), P3 (N4P), Pz (N5P), P4 (N6P), O1 (N1P), Oz (N2P), O2 (N3P)
(Lotte verwendet die Positionen P07, P08. Diese sind auf dem OpenBCI Headset jedoch nicht vorhanden. Deshalb wurden hier alternativ die Positionen O1 und O2 gewählt.)

Experiment Ablauf

1. 2x Daten von 5 Durchläufen mit einem Fokus auf Play aufzeichnen, Daten werden einmal fürs Training und einmal für Tests verwendet.
2. Baseline und Kommando Daten Bandpassfiltern auf 1 - 12 Hz
3. Daten in Slots von 120 Samples aufteilen
4. Für jeden Slot den Median der 8 Channels berechnen
5. Median der Channels auf 16 Samples down sampeln
6. Feature Vektoren erstellen:
X: trials * [samples]
y: trials * [target / non-target]
Anzahl Features: 137
Anzahl Target = 5
Anzahl Non-Target: 132
7. Feature Scaling
8. Daten Trainieren nach target (mit P300) und non-target (ohne P300)
9. Model Accuracy mit Testdaten prüfen
10. Test mit Livedaten

5.2.7 Erkenntnisse P300

Die zeitliche Synchronisation der Anzeigen im Musikplayer sowie der Signale vom EEG ist essentiell zur Verarbeitung von P300 Signalen. Nur wenn man die Daten möglichst genau dem Event zuordnen kann, ist eine akkurate Klassifizierung möglich. Durch die Synchronisation des Cyton Boards mit der Zeit des lokalen Computers sowie dem Vergleichen der Timestamps der GUI Kommandos zu den EEG Daten wurde dies sichergestellt.

Wenn weitere Datenquellen zu einem Projekt hinzugefügt werden, welche alle miteinander zeitlich synchronisiert sein müssen, so empfiehlt es sich, das Projekt auf Basis des LabStreamingLayer (LSL) Projektes aufzubauen (OpenBCI Lab Streaming Layer (LSL) 2016). Das LSL ist spezifisch dafür gemacht, verschiedene Quellen anhand der Timestamps zeitlich zu synchronisieren.

Die Hauptschwierigkeit bei der Klassifizierung der P300 Welle, ist das Abheben der P300 Welle gegenüber dem restlichen Signal (Noise). Ein simples Filtern der Daten, um die P300 direkt ablesen zu können, scheint zumindest mit der hier verwendeten Hardware nicht möglich. In der Literatur zu P300 werden meist komplexere EEG Headsets mit mehr als acht Elektroden verwendet. Zusätzlich wird in den meisten Fällen eine vorgängige Trainingsphase zur Verwendung von Machine Learning für die Klassifizierung eingesetzt. Die reine Filterung der Daten brachte in dieser Konstellation keinen Erfolg.

Die Verwendung einer Support Vector Maschine und acht Elektroden scheint ein Ansatz für eine bessere Klassifizierung zu sein. Für die Klassifizierung von P300 wird in der Literatur nicht nur SVM verwendet, sondern auch andere Klassifizierungsalgorithmen wie z.B. Linear discriminant analysis (LDA) (Lotte 2018, 4). Es könnte sich lohnen in einem nächsten Schritt andere Algorithmen für die Klassifizierung der P300 testen. Auch die Verwendung von mehr Trainingsdaten könnte, den Algorithmus verbessern.

Um den Machine Learning Ansatz weiter zu verfolgen, müsste im GUI eine Trainingsphase eingebaut werden, in der target und non-target Daten aufgenommen werden, um die SVM entsprechend zu trainieren. Da bei den durchgeführten Experimenten die P300 nicht in jedem Durchlauf aufgetreten ist, ist es schwierig sicherzustellen, dass die aufgenommenen target Daten wirklich alle auch eine P300 Welle enthalten. Dies kann den Algorithmus stark negativ beeinflussen und macht eine korrekte Klassifizierung mit Machine Learning sehr schwierig.

Bei längerer Benutzung des Musikplayers, könnte das Aufblinken der Symbole auf die Anwendenden störend wirken. Es könnte sinnvoll sein, auch hier eine Möglichkeit zur Aktivierung und Deaktivierung der Steuerung auszuarbeiten (siehe Kapitel 4.4 Aktivierungsmöglichkeiten einer Steuerung).

5.3 Steuerung durch Gedanken

Als dritte Aufgabe wurde eine Steuerung durch Gedanken angestrebt. Die Vorstellung einer Körperbewegung (Motor Imagery) löst im Gehirn sehr ähnliche Muster aus wie das effektive Durchführen der Bewegung. (Brandstetter 2017, 9) Bei dieser Art der Steuerung könnte im Gegensatz zu den bisherigen Konzepten, nach der initialen Trainingsphase auf das Betrachten des Bildschirms verzichtet werden. Dies könnte die Verwendung erleichtern, insbesondere für Anwendende mit eingeschränkter Mobilität. Als Ansatz zur Steuerung des Musikplayers mittels Gedanken, wurde die Verwendung der Motor Imagery EEG (MI-EEG) Analyse gewählt.

5.3.1 Motor Imagery

Die fünf verschiedenen Kommandos müssen für Anwendende individuell trainiert werden. Während einem Zeitraum von einigen Sekunden stellen sich die Anwendenden vor ihre rechte Hand zu öffnen und zu einer Faust zu schließen. Dies, als Signal um ein Lied weiter zu springen, also das Kommando "next" auszulösen. Das Signal wird dabei aufgenommen und gespeichert. In einer folgenden Weiterverarbeitung werden die speziellen Merkmale des Signals berechnet, welche zur Differenzierung der verschiedenen Kommandos dienen. Das "Common spatial pattern" (CSP) ist die meistgenutzte Methode, um Features aus Motor Imagery EEG Signalen zu extrahieren. Diese werden anschliessend mit einem Machine Learning Algorithmus klassifiziert. (Liu u. a. 2017, 5)

Der Musikplayer kann nach dem Training gesteuert werden, indem die Anwendenden sich erneut vorstellen ein Lied weiter zu springen. Die Steuerung erkennt das zuvor trainierte Signal wieder und führt das entsprechende Kommando aus.

Verschiedene Arbeiten beschreiben das Erkennen von Motor Imagery mittels Machine Learning. Oftmals sind als Voraussetzung aber Laborbedingungen und EEG-Hardware aus höheren Preissegmenten gesetzt.

Zur Klassifizierung werden folgende Phänomene und Informationsanteile aus den EEG Daten berücksichtigt. Die "Spatial information" beschreibt, von wo das Signal kommt. Aus den verschiedenen Kanälen werden unterschiedliche Positionen ausgewertet oder verschieden gewichtet. Die "Spectral (frequential) information" beschreibt, wie sich die Stärke der Signale in den verschiedenen Frequenzbändern verändert. Die "Temporal information" repräsentiert die zeitliche Komponente. (Lotte 2018, 5)

Oszillierende EEG Rhythmen, welche auf einem Ereignis basieren, zeigen entweder eine Verstärkung der Signalstärke in einem Frequenzband (Event Related Synchronisation (ERS)) oder eine Abschwächung/Verringerung der Signalstärke in einem Frequenzband (Event Related Desynchronisation (ERD)). (Lotte 2018, 6) Die Vorstellung einer linken Handbewegung führt zu einer kontralateralen (also rechtsseitigen) ERS (Verstärkung) in Alpha und Beta, während der Vorstellung, und zu einer ERD (Abschwächung) in Beta gleich nach der Vorstellung.

Im Folgenden werden die Voraussetzungen und Vorgehensempfehlungen nach Lotte (Lotte 2018) beschrieben.

Als Basic setup wird ein 32-Kanal BCI 250Hz verwendet. Um primär rechte von linken Handbewegungen zu unterscheiden, können die Frequenzbänder Alpha 8-12 Hz und Beta 16-24 Hz sowie mehrere Channels um die Region von C3 (links) für die rechte Hand und um C4 (rechts) für die linke Hand ausgewertet werden. Eine Feature Extraction aus den zwei Frequenzbändern wird bei einigen BCI Systemen bei jedem Subjekt unterschiedlich erfolgen. Dies durch eine Optimierung der Feature Parameter. Es lassen sich also nicht per se allgemein gültige Angaben machen. Es werden spektrale und räumliche (spatial) Informationen extrahiert. Ein Feature selection algorithm selektiert jeweils ein Subset der extrahierten Features. Ein Channel selection algorithm selektiert ein Subset von relevanten Channels aus allen vorhandenen. Sogenannte Spatial filtering algorithms fassen mehrere Kanäle mittels einer Gewichtung in einem zusammen. Davon gibt es zwei Unterarten: Der Bipolar spatial filter, welcher auf der Differenz der beiden benachbarten Elektroden basiert. (z.B. für $C3_{\text{bipolar}} = FC3 - CP3$). Und der Laplacian spatial filter, dieser ist definiert durch folgende Formel: $C3_{\text{Laplacian}} = 4 \cdot C3 - FC3 - C5 - C1 - CP3$. Es ist anzumerken, dass beide Varianten mit dem hier verwendeten Headset nicht möglich sind, da es an den direkt benachbarten Elektrodenpositionen sowie an ihrer Anzahl fehlt (siehe Abbildung 10).

Ein häufig verwendeter Algorithmus für die Feature Extraction ist der Common Spatial Patterns Algorithmus (CSP). Dazu wird der Bandpassfilter von 8-30 Hz verwendet (alpha und beta). Dieser Algorithmus findet spatial filters so, dass sich eine maximale Varianz zwischen den beiden Klassen (zwischen zwei Labels) ergibt. Jedoch benötigt der CSP mehr Elektroden als bei Bipolar oder Laplacian. Somit findet er keine Verwendung in dieser Arbeit. Der CSP ist zudem nicht robust gegen Noise und kann auch weitere Unzulänglichkeiten zeigen. Es besteht jedoch die Möglichkeit den CSP stabiler zu machen, indem man ein Regularisierungs Framework einsetzt, welches schlechte Entscheidungen des CSP unterdrückt, respektive anhand von bekannten guten Entscheidungen den CSP in die korrekte Richtung lenkt. Bleibt anzumerken, dass der CSP nur "spatial informationen" berücksichtigt, nicht aber spektrale, also welche Bandpassfilter zu verwenden sind. Dies kann entweder manuell geschehen (trial and error) oder es werden mehrere Frequenzbänder (durch eine sogenannte Filterbank) ausgewertet und mittels "Feature selection", das jeweils Relevante bestimmt. Als erfolgversprechendste Variante beschreibt Lotte folgendes Vorgehen: Zuerst wird eine Filterbank der verschiedenen Frequenzbänder erstellt, danach wird je ein CSP angewendet, um daraus eine Feature Selection zu treffen. Die anschließende Klassifikation kann dann mittels linearer Diskriminanten Analyse (LDA, auch Fisher's LDA) oder durch Support Vector Machines (SVM) erfolgen. Jedoch bemerkt auch Lotte, dass noch niemand den optimalen Algorithmus gefunden hat.

5.3.2 Motor Imagery für den Musikplayer

Für die Steuerung des Musikplayers wurden die Kommandos mit folgenden Bewegungsabläufen und Assoziationen verbunden. Um die Musikwiedergabe zu Starten (und auch zu Pausieren) soll man sich das Vorwärtsgehen vorstellen. Das Vorstellen des Öffnens und Schliessen der Hand, die rechte Hand um zum nächsten Song zu schalten, die linke Hand um zum vorherigen Song zu schalten. Das Öffnen des Mundes vorstellen, um die Lautstärke zu erhöhen. Das Bewegen der Füße vorstellen, um die Lautstärke zu reduzieren. Folgende Informationen werden im Musikplayer eingeblendet und vorgelesen.

Kommando	Vorinfo (vor Training)	Kurzinfo (während Training)
volup	If icon turns white, focus on volume up and think of opening your mouth.	volume up - open mouth
playpause	If icon turns white, focus on playing and think of going forward.	play - go forward
next	If icon turns white, focus on next and think of open and closing your right hand.	next - right hand
prev	If icon turns white, focus on prev and think of open and closing your left hand.	previous - left hand
voldown	If icon turns white, focus on volume down and think of moving your feet.	volume down - move feet

Tabelle 3 Motor Imagery für Steuerungskonzept Mind

Der Musikplayer wurde um ein drittes GUI erweitert für dieses Steuerungskonzept. Im Code sowie in der Anwendung wird es als Mind bezeichnet. Es zeigt die fünf Kommandos nebeneinander. Mittig darunter ist ein Trainings-Button platziert, mit welchem das Training gestartet werden kann.

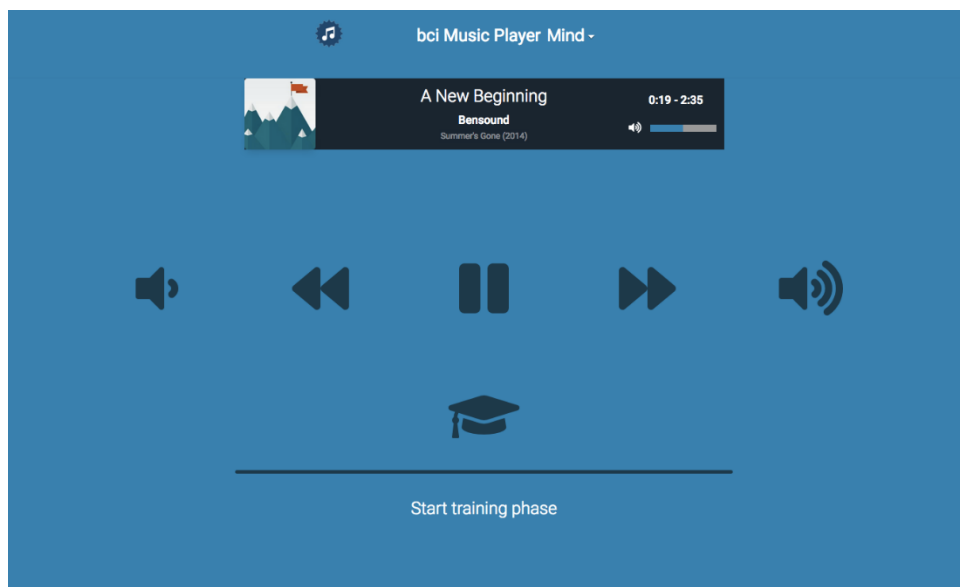


Abbildung 35 Musikplayer Mind

Wird die Trainingsschaltfläche geklickt, so werden die Steuerungsbuttons deaktiviert und ein eventuell noch laufendes Audio gestoppt. Danach erscheinen die Informationen unterhalb der Statusbar (horizontale Linie). Zuerst wird man darauf hingewiesen, ruhig und bequem zu sitzen. Dann folgen die

Anweisungen zu den einzelnen Kommandos. Zuerst erscheint eine Vorabinformation. Während dem Training wird eine Kurzinfo angezeigt (siehe Tabelle 3). Eine Statusbar signalisiert den Anwendenden, wann die Trainingsphase pro Kommando abgeschlossen ist. Alle fünf Kommandos werden nacheinander trainiert und aufgezeichnet. Dazwischen gibt es immer einen Unterbruch, bei dem die Anwendenden dazu aufgefordert werden ihre Konzentration wieder loszulassen und zu entspannen. Da dieses Steuerungskonzept schlussendlich ohne Bildschirm bedienbar sein sollte, werden die Anweisungen auch durch den Browser vorgelesen. („ResponsiveVoice Text To Speech“ 2018) Als weiteren Entwicklungsschritt für den Client wäre eine Visualisierung der Bewegungen durch die Einspielung eines Videos oder einer Animation denkbar.

5.3.3 Vorgehen Motor Imagery

Um das Steuerungskonzept Motor Imagery (Mind) auf der Vorstellung von Bewegungen (Motor Imagery) zu implementieren, wurde zuerst das GUI wie unter 5.3.2 Motor Imagery für den Musikplayer beschrieben erstellt. Dies ermöglichte die Aufzeichnung von Daten, welche danach ausgewertet werden sollen. Die Umsetzung wird im Folgenden erläutert. In einem ersten Experiment wurde versucht, die beiden Vorstellungen einer Handbewegung rechts und links zu differenzieren. In einem weiteren Schritt könnten die extrahierten Features für das Training des ML Algorithmus verwendet werden. Es wurde festgestellt, dass das Erkennen mit der verwendeten Hardware, nicht möglich ist. Dennoch wurde das Grundkonzept als Basis für eventuelle Folgeprojekte implementiert.

5.3.4 Umsetzung Motor Imagery

Wird im Musikplayer ein Training gestartet, so zeigt dieses die Anweisungen wie beschrieben an. Nach dieser Zeit wird mittels socket.io eine Nachricht an den Server gesendet, mit der Information, welches Kommando und wie lange trainiert wurde. Die Serveranwendung selektiert die vergangenen Daten dieser Länge und speichert ein json-File⁷ unter dem entsprechenden Namen des Kommandos ab. Dazwischen wird die Ruhephase (baseline) ebenfalls gespeichert. Sobald alle Kommandos trainiert wurden, sendet das GUI die Mitteilung zum Auswerten der Daten (init Training). Die Serverapplikation liest nun alle Daten der fünf Kommandos plus die Baseline ein. Die Daten werden anschliessend gefiltert und zum Training der Algorithmen verwendet.

⁷ JSON (JavaScript Object Notation) is a lightweight data-interchange format.(„JSON“ 2018)

5.3.5 Experiment Motor Imagery

Experiment 1 – Feature Extraction

Es soll untersucht werden, ob die Vorstellung von linken und rechten Handbewegungen unterschieden werden können. Das Experiment basiert auf Lotte "Basic design for an oscillatory activity-based BCI" (Lotte 2018, 7). Typischerweise wird die Elektroden Position C3 für rechte Handbewegungen und C4 für linke Handbewegungen benutzt. Laut Lotte sollten die „Spatial information“ in den Frequenzbändern 8-12 Hz und 16-24 Hz ersichtlich sein. Das bedeutet, dass beim Vorstellen der Bewegung der rechten Hand, die Signalstärke bei C3 in 8-12 Hz reduziert ist. Entsprechend wäre beim Vorstellen der Bewegung der linken Hand bei C4 ein reduziertes Signal zu erwarten. Im Weiteren wurde untersucht, ob das tatsächliche Ausführen der Bewegungen differenziert werden kann.

Die berechneten Werte aus den beiden Frequenzbändern gelten als Features, welche für die Verwendung von Machine Learning eingesetzt werden könnten.

Angeschlossene Channels: CZ (N1P), C3 (N2P), C4 (N3P), FZ (N4P), PZ (N5P), BIAS und SBR2

Trainingsschritte:

1. rechte Handbewegung vorstellen
2. linke Handbewegung vorstellen
3. rechte Hand bewegen
4. linke Hand bewegen
5. rechten Arm strecken

Experiment Ablauf

Ausgewertete Channels: C3, C4

1. Aufnahme der Daten
2. Pro Trainingsschritt die Daten von 0.5 - 1.5 Sekunden extrahieren von C3 und C4
3. Daten von C3 und C4 je einmal Filtern für die Frequenz 8 - 12 Hz und 16 - 24 Hz
4. Die vier gefilterten Datensätze quadrieren um die Signalstärke zu erhalten
5. Reduzieren der Werte auf den Durchschnitt (mean)

Ergebnis

Das Experiment wurde an zwei Probanden zu verschiedenen Zeitpunkten und an unterschiedlichen Orten durchgeführt. Sowohl durch die Vorstellung wie beim effektiven Ausführen der Bewegungen der Hände, wurden die EEG-Signale der kontralateralen Orte nicht wie erwartet gemessen. Es konnte somit keine Zuweisung erfolgen ob die rechte oder die linke Hand vorgestellt oder bewegt wurde.

5.3.6 Erkenntnisse Motor Imagery

Sowohl durch die Vorstellung einer Bewegung wie durch das Ausführen einer effektiven Bewegung, konnte aus den EEG Daten mit der in dieser Arbeit verwendeten Methodik keine Klassifizierung gefunden werden. Mögliche Gründe dafür können sein, dass einerseits sich die gesuchten Merkmale nicht bei jedem Subjekt in denselben Frequenzbändern zeigen. Andererseits sollten mehrere Elektroden verwendet werden, um genauere Daten zu erhalten. Die direkt benachbarten Positionen um C3, C4 stehen jedoch im OpenBCI Headset nicht zur Verfügung. Die Annahme, dass dies mit den vorhandenen Mitteln nicht möglich sein wird, wurde bestätigt. Es kann davon ausgegangen werden, dass das Verwenden von mehreren Elektroden zur Anwendung eines Spatial filtering algorithms wie in Kapitel 5.3.1 beschrieben ein erfolgreiches Ergebnis liefern.

Dennoch konnte durch das Erstellen des Musikplayers „Mind“ mit der Funktionalität zum Trainieren der Daten, eine Basis gelegt werden, für künftige Projekte.

5.4 Steuerungskonzepte Gegenüberstellung

Eine Gegenüberstellung der verschiedenen Steuerungskonzepte soll als Entscheidungshilfe dienen, mit welcher Variante in zukünftigen Projekten gearbeitet werden soll. Die Angaben der notwendigen Kanäle als Optimum sind dabei als Empfehlung anzusehen, da dies von sehr vielen Faktoren abhängig ist. Es ist festzuhalten, dass stirnbandähnliche EEG-Headsets mit wenigen Elektroden sich für Steuerungskonzepte wie das Blinzeln oder verschiedene Konzentrationszustände eignen mögen, sollen aber Phänomene, wie eine P300 oder Motor Imagery detektiert werden, benötigt man professionellere EEG-Headsets mit mehreren Elektroden. Die Anzahl von möglichen Kommandos ist je nach Steuerungskonzept und angestrebter User Experience ebenfalls als ungefähren Richtwert anzusehen. Beim den bildschirmabhängigen Konzepten wie Blinzeln und P300, läuft eine höhere Anzahl an Kommandos auf eine schwerfälligere und langsamere Bedienung heraus. Jedoch können P300 Varianten, welche auf einer Matrix basieren, gut auch 36 verschiedene Kommandos (beispielsweise alle Buchstaben und Zahlen) verwenden. Bei Motor Imagery sind die Anzahl der möglichen Kommandos durch die Anzahl der einfach feststellbaren Vorstellungen von Bewegungen limitiert. Die Trainingszeit wird mit jedem zusätzlichen Kommando verlängert, die effektive Anwendung ist davon jedoch nicht betroffen.

	Anzahl Kanäle Minimum	Anzahl Kanäle Optimum	Abhängig von Darstellung / Screen	Ohne Training	Anzahl Kommandos
Blinzeln	1	2	Ja	Ja	2 - 5
P300	8	16	Ja	Nein	5 - 36
Mind (Motor Imagery)	8 (Lotte 2018, 8)	48 (Lotte 2018, 8)	Nein	Nein	4 - 6

6 Fazit

In diesem Projekt konnte aufgezeigt werden, dass ein Brain Computer Interface gut zur Steuerung eines Musikplayers eingesetzt werden kann. Die Anzahl der notwendigen Steuerungskommandos lassen sich mit all den verschiedenen Konzepten umsetzen. In dieser Arbeit wurden drei verschiedene Konzepte exemplarisch aufgebaut. Ein webbasierter Musikplayer wurde implementiert. Der Musikplayer verwendet mit React ein aktuelles Webframework und kann beliebig ausgebaut werden.

Die Implementierung des Musikplayers sowie der OpenBCI Software wurde mittels Open Source Frameworks und Libraries erstellt. Aufgrund des Kundenwunsches das Projekt als Open Source zu gestalten, wurde bewusst auf proprietäre Software Pakete wie beispielsweise Matlab verzichtet. Das Github Repository mit dem Quellcode des Projektes wurde vor dem Projektabschluss an den Kunden übertragen, mit einem ausführlichen Readme, welches künftigen Entwicklern den Einstieg erleichtern soll. Mittels JSDoc wurde zusätzlich eine html-Dokumentation erstellt (JSDoc 2017).

Durch den Open Source Ansatz dieses Projektes war die Verwendung der OpenBCI Hardware als BCI naheliegend. Verglichen mit anderen low-cost BCI hat das OpenBCI den Vorteil, dass die Elektroden je nach Anwendung anders positioniert werden können und den Zugriff auf die Rohdaten uneingeschränkt möglich ist.

Die beschriebenen Steuerungskonzepte basieren auf drei verschiedenen Ansätzen. Die Elektroenzephalographie (EEG) lässt eine Vielzahl von Auswertungen zu. Verschiedene EEG-Muster und Ausschläge lassen sich ablesen und viele davon lassen sich auch gezielt evozieren.

Als erstes Steuerungskonzept wurde die Steuerung mittels eines Blinzeln umgesetzt. Das bewusste Blinzeln verursacht einen gut sichtbaren Ausschlag in den EEG Daten und kann daher einfach erkannt werden. Das Musikplayer GUI "Blink" ist einfach aufgebaut. Ein Aufleuchten iteriert über die verschiedenen Kommandos. Beim gewünschten Kommando kann dieses durch ein Blinzeln ausgelöst werden. Der grosse Vorteil dieser Steuerung ist, dass keine Trainingsphase notwendig ist und sie nur geringe Anforderungen an das BCI Headset stellt. Daher wäre es vorstellbar in einem weiteren Schritt das preiswerte Neurosky Headset für die Steuerung durch Blinzeln zu verwenden.

Das Erkennen der P300 Welle stellt die Basis des zweiten Steuerungskonzeptes dar. Das GUI "P300" im Musikplayer zeigt die verschiedenen Kommandos mit Zwischenräumen als grosse Quadrate in zwei Zeilen angeordnet an. Die Kommandos sowie die Zwischenräume leuchten in leichter Unordnung nacheinander auf. Durch ein Fokussieren auf ein Kommando wird ein Hervorrufen einer P300 Welle provoziert. Mit unterschiedlichen Ansätzen wurde versucht die P300 zu klassifizieren. Mit der zur Verfügung stehenden Hardware und Umgebung konnten jedoch nur vereinzelte P300 Wellen korrekt erkannt werden. Dieses Steuerungskonzept ist in der Literatur häufig beschrieben und liesse sich in jedem Fall noch weiterentwickeln. Mit mehr Trainingsdaten oder mit der Verwendung von anderen

Machine Learning Algorithmen könnte wohl möglich ein besseres Ergebnis erreicht werden. Auch eine abgeschirmte Aufzeichnung der Trainingsdaten wäre ein möglicher Baustein zum Gelingen. Dies widerspräche dann allerdings der angedachten Anwendung durch Endverbrauchernde, respektive der Anwendung in einem privaten Umfeld und nicht im Labor. Der Vorteil dieser Steuerung ist, dass sie auch von Anwendenden mit sehr grossen körperlichen Einschränkungen bedient werden kann. Auch könnte sie gut noch um weitere Kommandos ausgebaut werden.

Als drittes Steuerungskonzept wurde eine Steuerung durch Gedanken angestrebt. Insbesondere durch die Verwendung von Motor Imagery. Dies bezeichnet das Vorstellen von Körperbewegungen. Diese Steuerung ist nur durch die Verwendung von Machine Learning realisierbar. Das bedingt ein Trainieren der verschiedenen Kommandos durch das Subjekt. Das dazu notwendige Trainings-GUI "Mind" konnte als Vorarbeit erstellt werden. Eine Schaltfläche zum Starten des Trainings deaktiviert die aktuell laufende Musik und zeigt in der Folge die Anweisungen zum Training an. Die EEG Daten werden während der Trainingszeit aufgezeichnet und pro Kommando abgespeichert. Durch Machine Learning können die aufgezeichneten EEG Daten im Anschluss klassifiziert werden. Dies dient der Wiedererkennung der Signale zum Auslösen eines gewünschten Kommandos. Beim Aufzeichnen von motorischen Bewegungen wurde festgestellt, dass sich die OpenBCI Hardware nicht für diese Steuerung eignet und eine grössere Anzahl an Elektroden zwingend notwendig ist. Die vorhandene Hardware, das Fehlen eines EEG-Labors sowie einer fortgeschrittenen Anwendung von Machine Learning standen einer erfolgreichen Umsetzung im Weg.

Die Trainingsdaten müssten für das gleiche Subjekt bei jeder Verwendung wiederholt aufgezeichnet werden, da sich die Positionierung, der Allgemeinzustand sowie andere äussere Einflüsse in jeder Anwendung wieder etwas unterscheiden. Es stellt sich somit die Frage, ob es sich als Steuerungskonzept für die Endverwendenden praktikabel erweisen würde, wenn bei jeder Bedienung zuerst eine Trainingsphase absolviert werden muss. Ein Vorteil dieses Konzeptes wäre jedoch der Nichtgebrauch des Bildschirms nach erfolgtem und erfolgreichem Training. Die ersten beiden Steuerungskonzepte bedingen ein Betrachten des Bildschirms zur Steuerung.

In dieser Arbeit konnte eine Einführung in die Thematik sowie eine Analyse der verschiedenen Ansätze und Möglichkeiten erstellt werden. Die in dieser Arbeit gewonnen Erkenntnisse und erstellten Basisimplementierungen finden idealerweise in einem Folgeprojekt der FHNW oder durch Entwickler aus der BCI Community eine Weiterentwicklung. Durch die limitierten Möglichkeiten von OpenBCI konnte P300 und Mind nicht erfolgreich umgesetzt werden. In einer Weiterentwicklung wäre spannend zu sehen, welche Ergebnisse mit Hardware mit mehr Elektroden Positionen oder komplexeren Machine Learning Anwendungen möglich sein würden. Einen Ausbau des Musikplayers und eine zukünftige Anbindung an eine lokale Musikkbibliothek oder an Streamingdienste ist denkbar. Auch könnten in

einem nächsten Schritt weitere Interaktionen, wie beispielsweise eine Musikwahl je nach Konzentrationszustand oder das Erstellen von Favoriten-Playlisten ausgearbeitet werden.

Soll ein Interface zwischen Mensch und Maschine zur Steuerung verwendet werden, ohne das physische Drücken von Tasten, so liegt die Verwendung von Spracherkennung (Voice Control) nahe. Alexa, Google Home und Apples Homepod machen es vor. Die User können (fast) alles steuern, erfragen und kommunizieren via Sprache und ebenso einfach einen Musikplayer per Sprachbefehle bedienen. Als Nachteil im öffentlichen Raum, ist einzig die Tatsache zu nennen, dass alle mitkriegen, was man von seinem Device gerade erwünscht. Ein BCI ist da viel dezenter. Zudem ermöglicht ein BCI auch Personen mit Sprachbehinderungen eine Kontrollmöglichkeit.

Die Verwendung eines BCI zur Steuerung eines Musikplayers oder beliebiger anderer Anwendungen ist ein spannendes Gebiet, in dem es noch einiges zu erforschen gibt. Die aktuelle Entwicklung im Umfeld von BCIs ist erfreulich. Es finden sich viele Projekte und Artikel. Die Evolution der Hardware schreitet schnell voran. Laufend neue Gerätschaften ermöglichen neue Anwendungen. Viele Arbeiten aus der Bioinformatik, Neurologie, Psychologie und weiteren verwandten Bereichen beschreiben Ansätze zur Verwendung eines BCI. Wobei sich zumindest momentan noch praktikable Anwendungen auf die einfacheren Konzepte, wie das Feststellen eines Augenzwinkerns festlegen. Forschungsorientierte Laboranwendungen beschreiben aufwändigere Analysen. Die Möglichkeiten der verschiedenen Hardware-Sets und der immer leistungsfähigeren Machine Learning Algorithmen ermöglichen eine vielversprechende Weiterentwicklung. Das Aufzeichnen von "sauberen" Daten bleibt jedoch schwierig. EEG Daten, welche zu viele Störsignale enthalten, kann man auch mit den idealsten Methoden nicht zu reinen Signalen machen. Eine Verwendung als Steuerung scheint aber dennoch möglich zu sein. Ob sich die Gesellschaft bald anstatt mit einer Smartwatch mit einem Smartband (ein EEG-Stirnband) ausrüsten wird, bleibt abzuwarten. Die Smartwatches haben erstaunlich hohe Verkaufszahlen, scheinen aber dennoch nicht an jedem Handgelenk aufzutauchen. Vielleicht werden es ja Kopfhörer mit integrierten Trockenelektroden sein, welche den Durchbruch schaffen.

Die grössere Verbreitung würde auf jeden Fall eine Chance bieten, anhand der vielen Daten, welche konstant aufgezeichnet würden, neue Erkenntnisse über unsere Hirnströme zu erhalten.

7 Literaturverzeichnis

- Bauer, Joachim, und Hans Berger. 2011. *Das wissenschaftliche Gesamtwerk des Jenaer Nervenarztes Hans Berger*. Geschichte. Stuttgart: Steiner.
- Bear, Mark F. 2009. *Neurowissenschaften : ein grundlegendes Lehrbuch für Biologie, Medizin und Psychologie*. 3. Aufl. 2009. Heidelberg: Spektrum Akademischer Verlag Springer Spektrum.
- Birbaumer, Niels. 2006. „Breaking the Silence: Brain Computer Interfaces (BCI) for Communication and Motor Control“. *Psychophysiology* 43 (6): 517–32. <https://doi.org/10.1111/j.1469-8986.2006.00456.x>.
- Bougrain, Laurent, Carolina Saavedra, und Radu Ranta. 2012. „Finally, what is the best filter for P300 detection?“ *Proceedings of the 3rd TOBI Workshop*, März.
- Brandstetter, Julia. 2017. „Online Adaptation of a Brain Computer Interface Using Semi-Supervised Learning Techniques“. MSc Thesis. Graz, AT: TU Graz. <http://diglib.tugraz.at/download.php?id=5a1def36a37d1&location=aleph>.
- Chip. 2014. „EEG Hacker: Controlling a Hex Bug with my Brain Waves“. *EEG Hacker* (blog). 8. Juni 2014. <http://eeghacker.blogspot.com/2014/06/controlling-hex-bug-with-my-brain-waves.html>.
- Cohen, Mike X. 2014. *Analyzing Neural Time Series Data : Theory and Practice*. Issues in Clinical and Cognitive Neuropsychology. Cambridge, Massachusetts : The MIT Press.
- Emotiv Cortex. 2018. „Cortex API Documentation“. 2018. <https://emotiv.github.io/cortex-docs/#introduction>.
- „EMOTIV EPOC+ 14 Channel Mobile EEG“. 2018. *Emotiv* (blog). 2018. <https://www.emotiv.com/product/emotiv-epoc-14-channel-mobile-eeeg/>.
- „EMOTIV Insight 5 Channel Mobile EEG“. 2018. *Emotiv* (blog). 2018. <https://www.emotiv.com/product/emotiv-insight-5-channel-mobile-eeeg/>.
- „EPOC Flex Gel Sensor Kit“. 2018. *Emotiv* (blog). 2018. <https://www.emotiv.com/product/epoc-flex-gel-sensor-kit/>.
- Farnsworth, Bryn, und Ph.D. 2017. „EEG Headset Prices – An Overview of 15+ EEG Devices“. IMotions. 11. Juli 2017. <https://imotions.com/blog/eeg-headset-prices/>.
- „Font Awesome 5 Icons“. 2018. 2018. <https://origin.fontawesome.com/icons?d=gallery>.
- Goersch, Helmut. 2001. *Wörterbuch der Optometrie*. DOZ-Verlag Optische Fachveröffentlichung.
- „hack-the-brain-uk“. 2015. 2015. <http://openbci.com/community/hack-the-brain-uk-control-your-smartphone-by-winking/>.
- „Home - Psychiatrische Universitätsklinik Zürich (PUK)“. 2018. 2018. <https://www.pukzh.ch/>.
- „IMotions: Biometric Research, Simplified“. 2018. IMotions. 2018. <https://imotions.com/>.
- „InteraXon Muse - Meditationsassistent - MindTecStore“. 2018. InteraXon Muse - Meditationsassistent - MindTecStore. 2018. <https://www.mindtecstore.com/InteraXon-Muse-EEG-Headset>.
- JSDoc. 2017. „Use JSDoc: Index“. 2017. <http://usejsdoc.org/>.
- „JSON“. 2018. 2018. <https://www.json.org/>.
- Krusienski, Dean J., Eric W. Sellers, François Cabestaing, Sabri Bayoudh, Dennis J. McFarland, Theresa M. Vaughan, und Jonathan R. Wolpaw. 2006. „A Comparison of Classification Techniques for the P300 Speller“. *Journal of Neural Engineering* 3 (4): 299–305. <https://doi.org/10.1088/1741-2560/3/4/007>.
- Kübler, Andrea, Adrian Furdea, Sebastian Halder, Eva Maria Hammer, Femke Nijboer, und Boris Kotchoubey. 2009. „A Brain-Computer Interface Controlled Auditory Event-Related Potential (P300) Spelling System for Locked-in Patients“. *Annals of the New York Academy of Sciences* 1157 (März): 90–100. <https://doi.org/10.1111/j.1749-6632.2008.04122.x>.
- Lang, Gerhard K. 2014. *Augenheilkunde*. 5., überarbeitete Auflage. Stuttgart: Thieme.

- Le, Tan. 2018. *A Headset That Reads Your Brainwaves*.
https://www.ted.com/talks/tan_le_a_headset_that_reads_your_brainwaves.
- Li, Ting, Jinhua Zhang, Tao Xue, und Baozeng Wang. 2017. „Development of a Novel Motor Imagery Control Technique and Application in a Gaming Environment“. *Computational Intelligence and Neuroscience* 2017.
<https://doi.org/10.1155/2017/5863512>.
- Liu, Aiming, Kun Chen, Quan Liu, Qingsong Ai, Yi Xie, und Anqi Chen. 2017. „Feature Selection for Motor Imagery EEG Classification Based on Firefly Algorithm and Learning Automata“. *Sensors (Basel, Switzerland)* 17 (11).
<https://doi.org/10.3390/s17112576>.
- Lotte, Fabien. 2018. „A Tutorial on EEG Signal-processing Techniques for Mental-state Recognition in Brain–Computer Interfaces“. *springerprofessional.de*. 2018.
<https://www.springerprofessional.de/a-tutorial-on-eeeg-signal-processing-techniques-for-mental-state-/1804436>.
- Mahler, Philip. 2018. „EEG (Electroencephalography): The Complete Pocket Guide“. IMotions. 2018. <https://imotions.com/eeeg-guide-ebook/>.
- Malmivuo, Jaakko, und Robert Plonsey. 1995. *Bioelectromagnetism - Principles and Applications of Bioelectric and Biomagnetic Fields*.
<https://doi.org/10.1093/acprof:oso/9780195058239.001.0001>.
- Matran-Fernandez, Davide Valeriani and Ana. 2015. „EyeWink“. EyeWink. 2015.
<http://www.eyewink.net/>.
- MindWave Mobile 2. 2018. „Amazon.com: NeuroSky MindWave Mobile 2: Brainwave Starter Kit: Cell Phones & Accessories“. 2018. <https://www.amazon.com/NeuroSky-MindWave-Mobile-Brainwave-Starter/dp/B07CXN8NKX>.
- Mochajs. 2018. „Mocha - the fun, simple, flexible JavaScript test framework“. 2018.
<https://mochajs.org/>.
- Neurofeedback Organisation Schweiz. 2018. „Was ist Neurofeedback?“ 2018.
<https://www.neurofeedbackorg.ch/neurofeedback/was-ist-neurofeedback/>.
- Neurosky. 2018. „EEG Sensors - EEG Headsets | NeuroSky“. 2018.
<http://neurosky.com/biosensors/eeeg-sensor/biosensors/>.
- „Neurosky Apps“. 2018. 2018. <https://store.neurosky.com/collections/apps>.
- Node js Foundation. 2018. „Node.Js“. Node.Js. 2018. <https://nodejs.org/en/>.
- Nottaris, Angelo. 2017. *Steuerung eines Musik-Interfaces mittels Brain Computer Interface*. AV Akademikerverlag. <https://www.morebooks.shop/store/de/book/steuerung-eines-musik-interfaces-mittels-brain-computer-interface/isbn/978-620-2-20546-7>.
- Odom, James, Michael Bach, Colin Barber, Mitchell Brigell, Michael F Marmor, Alma Tormene, Graham Holder, und Vaegan. 2004. „Visual evoked potentials standard (2004)“. *Documenta ophthalmologica. Advances in ophthalmology* 108: 115–23.
- OpenBCI. 2018. „OpenBCI - Open Source Biosensing Tools (EEG, EMG, EKG, and more)“. 2018. <http://openbci.com/>.
- „OpenBCI GitHub“. 2018. GitHub. 2018. <https://github.com/OpenBCI>.
- OpenBCI Lab Streaming Layer (LSL)*. 2016. Python. OpenBCI.
https://github.com/OpenBCI/OpenBCI_LSL.
- OpenBCI node.js time-syncing*. 2017. JavaScript. OpenBCI.
https://github.com/OpenBCI/OpenBCI_NodeJS_Cyton#time-syncing.
- OpenBCI_NodeJS_Cyton*. 2017. *OpenBCI_NodeJS_Cyton: The official NodeJS driver for the Cyton board over Serial*. JavaScript. OpenBCI.
https://github.com/OpenBCI/OpenBCI_NodeJS_Cyton.
- „Processing.org“. 2018. 2018. <https://processing.org/>.
- Python. 2018. „Welcome to Python.Org“. Python.Org. 2018. <https://www.python.org/>.
- reactjs.org. 2018. „React - A JavaScript Library for Building User Interfaces“. 2018.
<https://reactjs.org/index.html>.
- „ResponsiveVoice Text To Speech“. 2018. ResponsiveVoice.JS. 2018.
<https://responsivevoice.org/>.

- Rosca, S., M. Leba, A. Ionica, und O. Gamulescu. 2018. „Quadcopter Control Using a BCI“. *IOP Conference Series: Materials Science and Engineering* 294 (1): 012048. <https://doi.org/10.1088/1757-899X/294/1/012048>.
- Rupp. 2018. „P300 – Psychotherapie Praxis Ch. Rupp“. 2018. <https://psychotherapie-rupp.com/tag/p300/>.
- Sachsenweger, Matthias. 1994. *Augenheilkunde (Duale Reihe) von Matthias Sachsenweger: Hippokrates Verlag* 9783777310787. <https://www.zvab.com/9783777310787/Augenheilkunde-Duale-Reihe-Matthias-Sachsenweger-3777310786/plp>.
- scikit-learn.org. 2018. „scikit-learn: machine learning in Python — scikit-learn 0.19.2 documentation“. 2018. <http://scikit-learn.org/stable/>.
- „SDK Muse“. 2018. *Muse Developers* (blog). 2018. <http://developer.choosemuse.com/sdk>.
- „Shy-Sort.Html“. 2018. Gist. 2018. <https://gist.github.com/lynn/ffe1f2ae55732ba4cebec010758ebf51>.
- Singh, Sanjay P. 2014. „Magnetoencephalography: Basic principles“. *Annals of Indian Academy of Neurology* 17 (Suppl 1): S107–12. <https://doi.org/10.4103/0972-2327.128676>.
- Socket.IO. 2018. „Socket.IO“. 2018. <https://socket.io/>.
- Wellach, Ingmar. 2015. *Praxisbuch EEG: Grundlagen, Befundung, Beurteilung und differenzialdiagnostische Abgrenzung*. 2., überarb. Aufl. Stuttgart: Thieme.
- Widmer, Job. 2018. *BCI Musicplayer*. <https://www.youtube.com/watch?v=8sczuNnF5al>.

8 Anhang

8.1 Projektantrag



HW

ML
Alg

IIT15: Musiksteuerung mit Brain Computer Interface

Betreuer: [Simon Schubiger](#)

Arbeitsumfang:	Priorität 1 P5 (180h pro Student)	Priorität 2 P6 (360h pro Student)
Teamgrösse:	2er Team	2er Team

Sprachen: Deutsch oder Englisch


Ausgangslage

Die Elektroenzephalografie (EEG), ist eine medizinische Methode, welche mittels Elektroden die Hirnstromaktivität misst. Das Brain Computer Interface ermöglicht es, diese Daten zu analysieren und als Steuerung zu nutzen. Zum Beispiel ist es möglich, mit einem Brain Computer Interface auch kleine Spiele zu spielen.

Ziel der Arbeit

In diesem Projekt geht es um die Interaktion zwischen dem Gehirn und Musik. Während des Musikhörens werden Hirnstromimpulse gemessen und analysiert. Im Projekt soll nun untersucht werden, welche Interaktionsmöglichkeiten mit der Musik sich daraus ergeben. Es sollen verschiedene Ansätze evaluiert werden, um die Hirnströme zu interpretieren.

In einem ersten Schritt soll die Regelung der Lautstärke und der Wechsel zwischen Songs implementiert werden. In einem zweiten Schritt sollen Playlists über Gedankenströme erstellt werden: Durch Vorstellen eines Musikstücks soll dieses automatisch erkannt und abgespielt werden.



Brain Computer Interface

Problemstellung

Die Eignung eines Brain Computer Interfaces für diese Aufgabe ist unklar. Weiter stellt Interpretation der gemessenen Daten durch den Computer eine Herausforderung dar.

Technologien/Fachliche Schwerpunkte/Referenzen

- <http://openbci.com>
- <https://store.neurosky.com/collections/apps>

Bemerkung

Dieses Projekt muss in einem einzigen Semester durchgeführt werden.

8.2 Aufgabenvereinbarung

Aufgabenvereinbarung BSc. Thesis (iP6-18fs_iit15)

Musiksteuerung für Brain-Computer-Interface

In diesem Projekt geht es um die Interaktion zwischen Gehirn und Musik. Im Projekt soll mittels openBCI (EEG) untersucht werden, welche Interaktionsmöglichkeiten mit der Musik sich realisieren lassen. Es sollen verschiedene Ansätze evaluiert werden, um die Hirnströme zu interpretieren.

Requirements

- Analyse der Signalverarbeitung von EEG Daten im Bezug auf mentale Kommandos
- Eignung der openBCI Hardware für diese Anwendung
- Prototyp Desktop-SW: SignalTraining mittels openBCI für 6 Commands
- Prototyp Desktop-SW: Musiksteuerung mittels openBCI für Zielgruppe TetraplegikerInnen
- Prioritäten der Steuerung:
 - Play
 - Stop
 - Next
 - Back
 - Vol up
 - Vol down
- Optionale Steuerungsfunktionen:
 - Musikwahl nach Mood
 - Songwahl durch vorangehendes Training beim Hören des Songs
 - Markieren eines Songs als Favorit (Playlist)
- Bericht, Poster
- BSc. Verteidigung

Meilensteine / Zeitachse

Monat	Feb			März			April			Mai			Juni			Juli			August			September										
Kalenderwoche	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24	25	26	27	28	29	30	31	32	33	34	35	36	37	38	39
Semesterwoche	1	2	3	4	5	6	7	8			9	10	11	12	13	14	15															
Meilensteine																																
Theoretischer Teil / Einarbeitung																																
Signalverarbeitung: Signal lesen																																
Signalverarbeitung: speichern (Commands)																																
Signalverarbeitung: PatternMatching																																
Trainings App (GUI)																																
iMusiksteuerungs App																																
Usability Tests																																
Doku/Präsis:																																
Bericht																																
Poster																																
Zwischenpräsentation Mai / Juni																																
Verteidigung																																
Stunden soll	4	6	8	16	8	8	16	8	8	16	8	8	8	16	8	8	8	25	22	22	22	22	22	22	22							

Brugg/Windisch, 10.04.2018


Ina Widmer


Michael Job


Auftraggeber: Angelo Nottaris


Betreuer: Simon Schubiger

9 Ehrlichkeitserklärung

Hiermit erklären wir, die vorliegende Projektarbeit selbständig, ohne Hilfe Dritter und nur unter Benutzung der angegebenen Quellen verfasst zu haben.

Basel, 16. August 2018



Ina Widmer



Michael Job